**ĐẠI HỌC BÁCH KHOA HÀ NỘI**

Học phần IT5440 – Nguyên lý và kỹ thuật phân tích chương trình (kỳ 2026.1)

# Phân tích các công trình liên quan và Đề cương nghiên cứu chi tiết

## Đề tài 5-KH – Chương 13: Mô hình ngôn ngữ lớn cho hiểu mã nguồn và phân tích chương trình


| | |
|---|---|
| Nhóm: | KHMT 2 (lớp Khoa học máy tính CH2026B) |
| Trưởng nhóm: | Nguyễn Tiến Luyện (MSHV 20262090M) |
| Giảng viên: | PGS. TS. Huỳnh Quyết Thắng |
| Phiên bản: | Bản nháp 1 – ngày 07/11/2026 |


**Tình trạng tài liệu.** Đây là tài liệu làm việc của nhóm, không phải báo cáo tiểu luận theo quy cách của hướng dẫn (báo cáo nộp dùng file Word mẫu riêng). Tài liệu phân biệt ba loại nội dung: (i) dữ kiện lấy từ các bài báo, (ii) nhận xét phê phán của người soạn, (iii) giả định cần nhóm hoặc giảng viên xác nhận. Các thiết kế thực nghiệm ở Phần II là đề xuất, **chưa được chạy thử**; mọi giả thuyết ở Phần II chưa có bằng chứng thực nghiệm.

# Mục lục


## I. Phân tích các công trình liên quan 5

### I.1. Phạm vi, phương pháp đọc và giới hạn 5

I.1.1. Phạm vi . . . 5
I.1.2. Mức độ đã đọc từng tài liệu . . . 5
I.1.3. Quy ước trình bày . . . 6
I.1.4. Giới hạn của quá trình tra cứu công trình liên quan . . . 6

### I.2. Bốn bài báo của Đề tài 5 7

I.2.1. Bài [1]: Khảo sát LLM cho kỹ nghệ phần mềm (Zhang và cộng sự) . . . 7
I.2.2. Bài [2]: Sense and Sensitivity (Štorek và cộng sự) . . . 8
I.2.3. Bài [3]: LLM giữa kỹ nghệ phần mềm và bảo mật phần mềm (Lin và cộng sự) . . . 12
I.2.4. Bài [4]: Code Comprehensor (Roychowdhury và cộng sự) . . . 13

### I.3. Các công trình bổ sung và kiểm tra tính mới 16

I.3.1. Công trình bổ sung đã xác minh trang tóm tắt . . . 16
I.3.2. Kết quả kiểm tra tính mới . . . 17

### I.4. Ánh xạ sang nội dung Chương 13 của đề cương học phần 18

### I.5. Tổng hợp và so sánh 19

## II. Đề cương nghiên cứu chi tiết 20

### II.1. Thông tin chung 20

### II.2. Tên đề tài đề xuất 20

### II.3. Tóm tắt 21

II.3.1. Tóm tắt (tiếng Việt) . . . 21
II.3.2. Abstract (English, proposal stage) . . . 21

### II.4. Bối cảnh, động cơ và phát biểu vấn đề 22

II.4.1. Bối cảnh . . . 22
II.4.2. Vấn đề . . . 22
II.4.3. Phát biểu bài toán hình thức . . . 22

**II.5. Tổng quan tóm tắt và khoảng trống nghiên cứu** **22**

**II.6. Mục tiêu, giả thuyết và câu hỏi nghiên cứu** **24**
II.6.1. Mục tiêu . . . . . 24
II.6.2. Câu hỏi nghiên cứu và giả thuyết . . . . . 25

**II.7. Đóng góp dự kiến và triết lý khoa học** **26**
II.7.1. Đóng góp dự kiến . . . . . 26
II.7.2. Triết lý khoa học áp dụng . . . . . 26

**II.8. Phương pháp nghiên cứu** **27**
II.8.1. Thiết kế tổng thể . . . . . 27
II.8.2. Định nghĩa và chỉ số . . . . . 27
II.8.3. Bộ dữ liệu . . . . . 28
II.8.4. Các điều kiện ngữ cảnh . . . . . 29
II.8.5. Mô hình và lời nhắc . . . . . 30
II.8.6. Thiết kế thống kê . . . . . 31
II.8.7. Kiểm chứng bằng thực thi (RQ3) . . . . . 31
II.8.8. Ước lượng ngân sách tính toán . . . . . 32

**II.9. Cách thức thực hiện** **32**
II.9.1. Quy trình theo bước . . . . . 32
II.9.2. Công cụ đề xuất . . . . . 33
II.9.3. Cấu trúc kho mã đề xuất . . . . . 33

**II.10. Tái lập và báo cáo theo quy trình tối thiểu** **34**

**II.11. Mối đe dọa đối với tính hợp lệ** **35**
II.11.1. Kiểm tra tái lập số liệu cơ sở của [2] . . . . . 35
II.11.2. Đạo đức, an toàn và sử dụng AI . . . . . 35

**II.12. Kế hoạch, phân công và tiến độ** **36**
II.12.1. Tiến độ . . . . . 36
II.12.2. Phân công theo vai trò . . . . . 36

**II.13. Rủi ro và phương án dự phòng** **37**

**II.14. Sản phẩm và đối chiếu với tiêu chí chấm** **38**
II.14.1. Cấu trúc bài báo dự kiến . . . . . 38

**II.15. Các điểm cần xác nhận** **39**

**Tài liệu tham khảo** **40**

**A. Ví dụ minh họa một mục của SemTrace-Dep** **41**

**B. Khuôn mẫu lời nhắc (đề xuất)** **42**

**C. Danh mục từ khóa tìm kiếm** **42**

**D. Các truy vấn tra cứu bổ sung đã thực hiện** **42**

**E. Thuật ngữ Việt – Anh** **43**

**F. Danh sách các điểm chưa xác minh** **43**

# Phần I.
# Phân tích các công trình liên quan

## I.1. Phạm vi, phương pháp đọc và giới hạn

### I.1.1. Phạm vi

Phần này phân tích bốn bài báo trong thư mục Đề tài 5 (Chương 13) do giảng viên cung cấp, ký hiệu [1, 2, 3, 4], và các công trình bổ sung do người soạn tìm thêm để kiểm tra khoảng trống nghiên cứu [6, 7, 8, 9, 10, 11, 12, 13, 14].

**Giả định về cụm từ "các công trình của thầy"**

Yêu cầu ban đầu ghi "các công trình paper của thầy". Người soạn hiểu là các bài báo do giảng viên lựa chọn cho Đề tài 5 (hướng dẫn tiểu luận ghi giảng viên chọn 03 bài mỗi đề tài; thư mục có 04 bài). Nếu ý là các công bố do chính PGS. TS. Huỳnh Quyết Thắng là tác giả, phần này chưa bao quát nội dung đó và cần bổ sung sau khi nhóm có danh sách công bố.

### I.1.2. Mức độ đã đọc từng tài liệu

Bảng 1 ghi rõ phần đã đọc để người dùng biết mức độ tin cậy của từng mục phân tích.

**Bảng 1.** Mức độ đã đọc các tài liệu

| Tài liệu | Phần đã đọc | Phần chưa đọc hoặc chưa kiểm tra |
|---|---|---|
| [1] | Tóm tắt, giới thiệu, phương pháp khảo sát, thống kê chính, phần thách thức (mục 6), tìm kiếm từ khóa | Phần lớn mục 3–5 (từng nghiên cứu cụ thể) chỉ đọc lướt qua tiêu đề mục và các đoạn liên quan đến tóm tắt mã, tìm kiếm mã |
| [2] | Toàn bộ nội dung chính (mục 1–7), các bảng chính, phần hạn chế | Phụ lục (kết quả chi tiết cho mô hình nhỏ, JavaScript, PHP) chỉ đọc số liệu tổng hợp trong nội dung chính; chưa chạy mã nguồn của tác giả |
| [3] | Tóm tắt, mục 2 (phương pháp), mục 4 (khung bảo đảm), mục 7.5 (quy trình báo cáo), mục 8.6–8.7, kết luận | Các mục 5–6 (tổng hợp theo tác vụ) và mục 7.1–7.4 (điểm chuẩn) chỉ đọc lướt qua tiêu đề |
| [4] | Tóm tắt, giới thiệu, phần phương pháp, kết quả (Bảng I–III), chi phí, mối đe dọa tính hợp lệ, kết luận | Chưa chạy hay đối chiếu với mã nguồn (không thấy liên kết mã nguồn trong phần đã đọc) |
| [6, 7, 8, 9, 10, 11, 12, 13, 14] | Chỉ đọc trang tóm tắt hoặc bản tóm lược trang nguồn trả về | Toàn văn chưa đọc; số liệu chỉ là số liệu tóm tắt do tác giả công bố |

### I.1.3. Quy ước trình bày

Mỗi bài trong mục I.2 có ba phần: thông tin và dữ kiện do tác giả công bố (hộp xám), nhận xét phê phán của người soạn (hộp cam), và liên hệ với đề tài. Các nhận xét phê phán là diễn giải, có thể sai, và cần nhóm kiểm tra trước khi đưa vào bài viết. Các con số trích từ bài gốc được giữ nguyên đơn vị mà tác giả dùng (điểm phần trăm hoặc thay đổi tương đối); khi bài gốc không nêu rõ, tài liệu này ghi chú là chưa rõ.

### I.1.4. Giới hạn của quá trình tra cứu công trình liên quan

Việc tra cứu công trình liên quan dùng công cụ tìm kiếm web với khoảng 9 truy vấn, không phải tổng quan hệ thống. Kết quả "không tìm thấy công trình trùng khít" ở mục I.3 chỉ cho biết các truy vấn đó không trả về công trình như vậy, không chứng minh công trình đó không tồn tại.

# I.2. Bốn bài báo của Đề tài 5

**Bảng 2.** Tổng quan bốn bài báo của Đề tài 5

| Mã | Loại | Định danh, thời điểm | Nội dung chính | Mục 13.x liên quan |
|---|---|---|---|---|
| [1] | Khảo sát hệ thống về LLM cho kỹ nghệ phần mềm | arXiv:2312.15223v2, 09/2024 | Phân loại LLM cho mã, tác vụ kỹ nghệ phần mềm, vấn đề tích hợp và thách thức | 13.1–13.6 |
| [2] | Nghiên cứu thực nghiệm có đối chứng | arXiv:2505.13353v5, 07/2026 | Phân biệt khả năng nhớ nguyên văn và nhớ ngữ nghĩa thực thi của mã trong ngữ cảnh dài; tác vụ SemTrace | 13.7, 13.10, 13.11 |
| [3] | Khảo sát có cấu trúc, đề xuất khung đánh giá | arXiv:2608.21107v1, 08/2026 | Khung bảo đảm, thang bằng chứng E1–E4, quy trình báo cáo tối thiểu, chương trình nghiên cứu | 13.10, 13.11 |
| [4] | Đề xuất hệ thống và đánh giá | arXiv:2610.30016v2, 10/2026 | Hiểu kho mã lớn bằng đồ thị gọi hàm, tài liệu phân cấp do LLM sinh và truy xuất văn bản–mã | 13.2, 13.5, 13.6, 13.8 |

## I.2.1. Bài [1]: Khảo sát LLM cho kỹ nghệ phần mềm (Zhang và cộng sự)

**Dữ kiện do tác giả công bố**

- **Nhóm tác giả**: Q. Zhang, C. Fang, Y. Xie, Y. Zhang, Y. Yang, W. Sun, S. Yu, Z. Chen (Đại học Nam Kinh và một số đơn vị khác). Phiên bản v2, ngày 08/09/2024.
- **Quy mô**: 62 LLM cho mã thuộc ba kiến trúc, 15 mục tiêu tiền huấn luyện thuộc bốn nhóm, 16 tác vụ hạ nguồn thuộc năm nhóm, và 947 nghiên cứu thuộc 112 tác vụ liên quan đến mã trong năm giai đoạn của quy trình kỹ nghệ phần mềm.
- **Câu hỏi nghiên cứu**: RQ1 (góc nhìn LLM: các LLM đã phát hành, nhiệm vụ tiền huấn luyện, tác vụ hạ nguồn, mức độ mã nguồn mở), RQ2 (góc nhìn kỹ nghệ phần mềm: các tác vụ được hỗ trợ), RQ3 (góc nhìn tích hợp: các yếu tố then chốt khi đưa LLM vào kỹ nghệ phần mềm).
- **Quy trình chọn bài**: tìm kiếm tự động theo hai bộ từ khóa trên Google Scholar, ACM Digital Library và IEEE Xplore đến tháng 08/2024, thu được 32 560 bài; loại bài trước 2017 và bài dưới 7 trang; hai tác giả duyệt thủ công độc lập, tác giả thứ ba quyết định

khi bất đồng; sau đó tìm theo chuỗi trích dẫn. Kết quả ban đầu: 59 bài về LLM cho mã và 912 bài về kỹ nghệ phần mềm dựa trên LLM.

- **Thống kê liên quan đến Chương 13**: tóm tắt mã nguồn có 41 nghiên cứu, tìm kiếm mã có 19 nghiên cứu (theo bảng thống kê tác vụ của bài).
- **Thách thức do tác giả nêu**: đánh đổi giữa hiệu quả và kích thước mô hình; thiếu LLM chuyên biệt theo miền; cần bộ dữ liệu đánh giá sạch (nguy cơ rò rỉ dữ liệu, đề xuất ba nguồn: chương trình viết tay, chương trình mới, dự án đóng); phạm vi tác vụ còn lệch về phát triển, kiểm thử, bảo trì; LLM đa phương thức; khả năng giải thích.
- **Tài nguyên**: kho trực tuyến cập nhật liên tục `https://github.com/iSEngLab/AwesomeLLM4SE`.

**Nhận xét phê phán (diễn giải của nhóm, chưa kiểm chứng độc lập)**

- **Giới hạn thời điểm**: khảo sát dừng ở tháng 08/2024. Kết quả tìm từ khóa *hallucinat* và *context window* trong bản văn bản trích xuất của bài không có kết quả (phép trích xuất có thể thiếu sót). Nếu đúng, bài chưa phản ánh các nội dung trọng tâm của Chương 13 như hiện tượng bịa đặt và giới hạn cửa sổ ngữ cảnh, cũng như tác tử cấp kho mã và mô hình ngữ cảnh rất dài xuất hiện sau đó.
- **Bản chất bằng chứng**: bài đếm số công trình theo tác vụ, không tổng hợp định lượng kích thước hiệu ứng. Số 947 không cho biết LLM hiệu quả đến đâu trên tác vụ nào.
- **Chất lượng nguồn**: trong Bảng 1 của bài, 382 công trình được ghi loại "N.A." ở cột địa điểm công bố. Người soạn hiểu đó là các công trình không có địa điểm công bố xác định (có thể là bản tiền ấn phẩm), nhưng chưa kiểm chứng cách hiểu này.
- **Dùng làm gì**: nguồn phân loại và từ khóa cho phần tổng quan; không nên dùng làm bằng chứng cho một tuyên bố định lượng về năng lực hiểu mã hiện tại.

**Liên hệ với đề tài.** Cung cấp khung phân loại tác vụ (tóm tắt, tìm kiếm, sinh mã) cho mục 13.3–13.6, danh mục mô hình và biểu diễn cho mục 13.1–13.2, và lập luận về rò rỉ dữ liệu đánh giá, là một lý do để thiết kế bộ dữ liệu sinh tự động ở Phần II.

## I.2.2. Bài [2]: Sense and Sensitivity (Štorek và cộng sự)

**Dữ kiện do tác giả công bố – vấn đề và đóng góp**

- **Nhóm tác giả**: A. Štorek, M. Gupta, S. Hajizadeh, P. Srivastava, S. Jana (Đại học Columbia). Phiên bản v5, ngày 10/07/2026 (thể loại cs.CL). Các tìm kiếm cho thấy bản v1 và v2 có tựa "…Long Context Code Reasoning", các bản sau đổi thành "…Long Context Code Understanding". Mã nguồn: `https://github.com/adamstorek/long`

`-context-code-understanding` (theo chú thích của bài).

- **Câu hỏi**: khi LLM giải tác vụ hiểu mã trong ngữ cảnh dài, mô hình xử lý chính đoạn mã được cung cấp hay áp dụng các mẫu đã ghi nhớ khi tiền huấn luyện?
- **Định nghĩa**: *lexical recall* $R_{\mathrm{L}}$ là khả năng định vị và tái tạo mã nguyên văn; *semantic recall* $R_{\mathrm{S}}$ là khả năng nhớ mã làm gì khi chạy, tức ngữ nghĩa thực thi.
- **Ba đóng góp**: (1) phân biệt hai loại recall và chỉ ra chúng tách rời trong ngữ cảnh dài (xác nhận thêm trên Python, JavaScript, PHP); (2) đề xuất *semantic recall sensitivity* (độ nhạy khôi phục ngữ nghĩa) với phương pháp đo đối chứng bằng cách bỏ dòng lệnh; (3) đề xuất tác vụ SemTrace.

**Dữ kiện – phương pháp**

- **Độ nhạy**: gọi $\mathrm{Inc}(C)$ là tập các phiên bản không đầy đủ của đoạn mã $C$ (bỏ dòng lệnh), $R_T$ là kết quả của mô hình trên tác vụ $T$, $\epsilon > 0$ là hằng số ổn định số học. Độ nhạy được định nghĩa

$$\mathrm{Sens}_T(C) = \frac{1}{|\mathrm{Inc}(C)|} \sum_{C_{\mathrm{inc}} \in \mathrm{Inc}(C)} \frac{R_T(C) - R_T(C_{\mathrm{inc}})}{R_T(C) + \epsilon}. \tag{1}$$

  Độ nhạy cao nghĩa là hiệu năng giảm nhanh khi bỏ thông tin, tức tác vụ đòi hỏi nhớ đúng ngữ nghĩa của mã. Bộ thông dịch Python được dùng làm mốc tham chiếu: bỏ một dòng làm độ chính xác giảm 76 điểm phần trăm và gần bằng 0 khi bỏ quá 20% số dòng.
- **SemTrace**: hàm Python nhận số nguyên $x$, khởi tạo một danh sách, rồi gán cho từng phần tử riêng biệt giá trị $x + y$ ($y$ lấy đều trong $[-100, 99]$), thứ tự các dòng gán được hoán vị ngẫu nhiên; mô hình phải dự đoán danh sách trả về. Phép toán là cộng/trừ hai chữ số nhằm hạn chế yếu tố suy luận.
- **Thiết lập**: mã đích được đặt giữa các hàm gây nhiễu lấy từ CodeSearchNet-Python, lọc theo số ký tự (phân vị 25–75, khoảng 200 token mỗi hàm); 20, 40, 60, 80 hàm gây nhiễu (khoảng 4 k đến 16 k token). Lời nhắc dùng query-aware contextualization (đặt câu hỏi cả trước và sau mã). Đo độ chính xác khớp chính xác, không dùng ví dụ mẫu, giải mã tham lam. Thay đổi tương đối tính theo phần trăm so với giá trị cực đại của từng mô hình tại từng độ dài ngữ cảnh.
- **Mô hình**: 10 LLM gồm GPT-4.1 (2025/04/14), năm mô hình trọng số mở (DeepSeek Coder V2 Instruct, Gemma 3 27B, Llama 3.3 70B, Qwen 2.5 Coder 32B, Codestral 22B v0.1) và bốn mô hình nhỏ hơn. Mô hình mở được chạy bằng vLLM trên một máy AWS p5e.48xlarge; với GPT-4.1 chỉ dùng một phần tám mỗi bộ dữ liệu để giảm chi phí.

- **Đối chứng ngôn ngữ**: CRUXEval-X (JavaScript, PHP) và bản dịch SemTrace-JS, SemTrace-PHP, trên bốn mô hình.

**Bảng 3.** Độ chính xác (%) không có hàm gây nhiễu, theo Bảng 1 của [2]

| Mô hình | CRUXEval-I | CRUXEval-O | SemTrace |
|---|---|---|---|
| Codestral 22B | 44,62 | 50,38 | 23,25 |
| GPT-4.1 | 79,00 | 77,00 | 100,00 |
| DeepSeek Coder V2 | 36,50 | 54,00 | 96,00 |
| Gemma 3 27B | 50,62 | 25,87 | 12,25 |
| Llama 3.3 70B | 18,25 | 56,75 | 87,12 |
| Qwen 2.5 Coder 32B | 45,50 | 61,75 | 85,25 |

**Dữ kiện – kết quả**

- **Lexical recall**: các mô hình tiên tiến đạt trên 95% độ chính xác truy xuất hàm bất kể vị trí.
- **Semantic recall trên CRUXEval**: độ chính xác tương đối giảm 16,25–84,29% so với cực đại; giảm mạnh nhất khi mã ở vị trí 60–80% ngữ cảnh; hiện tượng đã xuất hiện với 20 hàm gây nhiễu (khoảng 4 k token).
- **Semantic recall trên SemTrace**: Qwen 2.5 Coder 32B mất 91,38% độ chính xác tương đối (giảm 53 điểm phần trăm) ở 80 hàm gây nhiễu, so với 23,31% trên CRUXEval-O; Codestral 22B và Gemma 3 27B giảm về 0. Trung vị mức giảm là 92,73% (SemTrace) so với 53,36% (CRUXEval).
- **Đối chứng bằng cách bỏ dòng lệnh**: từ mỗi hàm CRUXEval, tác giả tạo 71 994 phiên bản thiếu dòng. Bỏ 50% số dòng chỉ làm độ chính xác giảm 44,15% (dự đoán đầu vào) và 59,74% (dự đoán đầu ra), trái với bộ thông dịch giảm theo hàm mũ; tác giả diễn giải là mô hình dùng lối tắt khớp mẫu.
- **Ngôn ngữ khác**: trung vị mức giảm tương đối 34,72% (JS) và 14,35% (PHP) trên CRUXEval, 80,39% (JS) và 76,12% (PHP) trên SemTrace.
- **GPT-4.1**: đạt hầu như tuyệt đối trên SemTrace hai chữ số tại mọi vị trí; tác giả giả thuyết mô hình đã ghi nhớ phép cộng/trừ hai chữ số. Khi tăng lên 4 chữ số, độ chính xác giảm tới 31 điểm phần trăm ở vị trí giữa; với 6 chữ số, mất tới 43% tương đối, đường cong hình chữ U.

**Dữ kiện – hạn chế do tác giả nêu**

(1) Hàm gây nhiễu chọn ngẫu nhiên, không liên quan ngữ nghĩa, trong khi kho mã thực có hàm liên quan gây nhiễu; tác giả dự đoán ảnh hưởng sẽ xấu hơn nhưng chưa đo. (2) Phạm vi tác vụ chỉ gồm dự đoán vào/ra và truy xuất mã. (3) SemTrace dùng phép toán đơn giản, và việc GPT-4.1 ghi nhớ số học là giới hạn vốn có.

**Nhận xét phê phán (diễn giải của nhóm, chưa kiểm chứng độc lập)**

- **Đơn vị của con số 92,73%**: bài dùng thay đổi *tương đối* so với cực đại của từng mô hình, không phải điểm phần trăm; tóm tắt của bài viết "median accuracy drops" dễ bị hiểu là điểm phần trăm. Phần đã đọc chưa nêu rõ trung vị được lấy trên tập nào (mô hình, độ dài, vị trí). Nhóm cần đọc kỹ chú giải Hình 2 và mã nguồn trước khi trích số này.
- **Độ dài ngữ cảnh**: lớn nhất khoảng 16 k token. Cửa sổ ngữ cảnh danh định của các mô hình hiện hành lớn hơn nhiều, nên việc ngoại suy kết quả sang ngữ cảnh dài hơn chưa có cơ sở.
- **Thế hệ mô hình**: các mô hình được đánh giá thuộc giai đoạn 2024–2025. Tại tháng 11/2026 có các mô hình mới hơn; chưa có bằng chứng về việc hiệu ứng còn tồn tại hay không với các mô hình này. Đây là cơ sở cho RQ1 ở Phần II.
- **Giả thuyết ghi nhớ số học của GPT-4.1**: dữ liệu (hiệu ứng vị trí xuất hiện khi tăng số chữ số) nhất quán với giả thuyết nhưng không loại trừ giải thích khác (ví dụ độ khó tăng khi số chữ số tăng).
- **Chỉ chẩn đoán, chưa can thiệp**: bài không thử biện pháp giảm nhẹ (sắp xếp lại ngữ cảnh, chọn lọc mã, truy xuất). Đây là khoảng trống mà RQ2 nhắm tới.
- **Tình trạng bình duyệt**: không xác minh được. Tựa bài đổi giữa các phiên bản, cần xem bản cuối khi trích dẫn.

**Liên hệ với đề tài.** Là nền tảng trực tiếp: mục 13.7 (suy luận nhiều bước), 13.10 (cửa sổ ngữ cảnh) và 13.11 (giới hạn). SemTrace mô tả đủ chi tiết để cài đặt lại bộ sinh dữ liệu.

## I.2.3. Bài [3]: LLM giữa kỹ nghệ phần mềm và bảo mật phần mềm (Lin và cộng sự)

**Dữ kiện do tác giả công bố**

- **Nhóm tác giả**: W. Lin, T. Zhou, Z. Xie, C. Hong (Nanjing Liancheng Intelligent Technology Group). arXiv:2608.21107v1, ngày 21/08/2026 (cs.AI). Phạm vi: các công trình có sẵn đến ngày 31/05/2026.
- **Bốn câu hỏi nghiên cứu**: RQ1 (tác vụ kỹ nghệ và bảo mật phần mềm được LLM xử lý và ngữ cảnh cần có), RQ2 (prompting, tinh chỉnh, truy xuất, dùng công cụ thay đổi năng lực và kiểu thất bại thế nào), RQ3 (điểm chuẩn và chỉ số nào cho bằng chứng đáng tin; mối đe dọa tính hợp lệ nào cản trở so sánh), RQ4 (kỹ nghệ và bảo mật giao nhau ở đâu; cần cơ chế đánh giá và quản trị nào).
- **Khung cấu hình đánh giá**: $E = \langle A, C, M, T, V, B, H \rangle$ với $A$ là tác vụ và sản phẩm phần mềm, $C$ ngữ cảnh, $M$ mô hình và thích nghi, $T$ công cụ và quyền, $V$ bộ kiểm chứng, $B$ ngân sách suy luận và thử lại, $H$ can thiệp của con người; hai điểm số chỉ so sánh trực tiếp được khi các thành phần được kiểm soát hoặc phân tích rõ.
- **Thang bằng chứng**: E1 (minh họa), E2 (điểm chuẩn có kiểm soát), E3 (kho mã và môi trường thực thi), E4 (vận hành hoặc dài hạn); mỗi mức chỉ hỗ trợ một mức độ tuyên bố nhất định.
- **Bậc quyền của tác tử**: G0 (chỉ đọc), G1 (đề xuất bản vá, không chạy), G2 (sửa và chạy trong môi trường cô lập), G3 (tác động kho dùng chung, thông tin xác thực hoặc triển khai).
- **Mối đe dọa lặp lại**: bộ kiểm thử yếu, dữ liệu trùng lặp hoặc rò rỉ theo thời gian, thay đổi khung chạy tác tử, kiểm tra bảo mật chỉ qua chỉ báo gián tiếp, ngân sách và can thiệp của con người bị báo cáo thiếu.
- **Quy trình báo cáo tối thiểu** (Bảng 5 của bài) gồm bảy nhóm: tác vụ và đối tượng; mô hình và thích nghi; khung chạy và công cụ; ngân sách và đầu vào của con người; dữ liệu và nhiễm dữ liệu; kiểm chứng; độ bất định và thất bại.
- **Chương trình nghiên cứu** (Bảng 8 của bài): sáu hướng gồm sinh mã an toàn có chức năng chung, ngữ cảnh kho mã và tác tử, tập hợp bộ kiểm chứng và phản hồi của người, tự chủ có giới hạn rủi ro, bảo trì dài hạn, đánh giá liên tục và đa ngôn ngữ. Với hướng "ngữ cảnh kho mã và tác tử", câu hỏi là: mức cải thiện đến từ truy xuất, mô hình, khung chạy, công cụ hay lần thử lại thêm; bằng chứng tối thiểu gồm loại bỏ từng thành phần có kiểm soát, ngân sách cân bằng, nhật ký công cụ và nhiều dự án.
- **Giới hạn do tác giả nêu**: đây là tổng quan tường thuật có cấu trúc dựng từ một kho nguồn có thể truy vết, chưa phải tìm kiếm vét cạn với hai người sàng lọc độc lập; không

gộp điểm số vì khác mô hình, dữ liệu, lời nhắc và giao thức; tính hợp lệ theo thời gian rất mong manh vì mô hình và bảng xếp hạng thay đổi nhanh.

**Nhận xét phê phán (diễn giải của nhóm, chưa kiểm chứng độc lập)**

- **Nguồn tài liệu**: bài nêu kho nguồn được tạo tự động từ các khóa trích dẫn trong tệp nguồn của bài; phán đoán của người đánh giá và độ đồng thuận sàng lọc được để lại cho việc mã hóa thủ công trong tương lai. Điều này cho thấy việc sàng lọc độc lập bởi người đánh giá chưa được thực hiện; chọn nguồn theo trích dẫn của chính tác giả có thể thiên lệch.
- **Mức độ xác nhận**: khung bảo đảm, thang bằng chứng và quy trình báo cáo là đề xuất khái niệm; trong phần đã đọc không có xác nhận thực nghiệm rằng khung này cải thiện chất lượng đánh giá. Nên coi là danh mục kiểm tra hợp lý, không phải phương pháp đã được kiểm chứng.
- **Tình trạng bình duyệt**: bản tiền ấn phẩm v1 của một đơn vị công nghiệp, chưa xác minh bình duyệt.
- **Mức liên quan**: bài không tập trung vào hiểu mã nguồn. Giá trị với đề tài nằm ở phương pháp: mức bằng chứng nào cho phép tuyên bố điều gì, và danh mục thông tin cần báo cáo.

**Liên hệ với đề tài.** Cung cấp (i) cách giới hạn tuyên bố ở mức E2 nếu chỉ dùng điểm chuẩn có kiểm soát, (ii) Bảng 5 của bài làm khung báo cáo thực nghiệm (đã dùng ở Bảng 5.1 của file Word mẫu và ở mục II.10), (iii) hướng "ngữ cảnh kho mã và tác tử" trong Bảng 8 là một câu hỏi tương thích trực tiếp với RQ2 ở Phần II.

## I.2.4. Bài [4]: Code Comprehensor (Roychowdhury và cộng sự)

**Dữ kiện do tác giả công bố – hệ thống**

- **Nhóm tác giả**: S. Roychowdhury, J. H. R. Isaac, J. Gao, M. Klitte, D. Corcoran (Ericsson R&D). arXiv:2610.30016v2, ngày 22/10/2026 (cs.SE).
- **Vấn đề**: hiểu kho mã lớn; đưa toàn bộ kho vào ngữ cảnh LLM làm tăng chi phí và được dẫn là cho kết quả kém hơn; kho mã có nhiều tệp, hàm, biến giống nhau nên cần cách điều hướng nhất quán hơn.
- **CodeGraph**: phân tích tĩnh (Tree-sitter) dựng đồ thị tệp–hàm (thêm lớp với ngôn ngữ hướng đối tượng), lưu bằng NetworkX, cung cấp qua FastAPI các điểm truy cập duyệt đồ thị (BFS, DFS, cạnh gọi theo cả hai chiều).
- **CodeScribe**: sinh tài liệu phân cấp bằng LLM theo cấu trúc thư mục, mỗi thư mục có

thể có nhiều "chương" (mô tả mã, thuật toán, luồng dữ liệu, giao diện); thuật toán chia theo thứ tự hậu tố trên cây gọi (post-order chunking) với tóm tắt cuốn chiếu để mô hình biết tóm tắt các hàm được gọi dù mã nguồn của chúng không nằm trong cửa sổ hiện tại.

- **CodeContrast**: bộ mã hóa kép kiểu CLIP, huấn luyện đối sánh trên đầu ra của CodeScribe, với lô toàn cục gom qua nhiều GPU (FSDP).
- **Master Agent**: bộ điều phối LLM qua cổng MCP gọi các tác tử chuyên biệt (CodeScribe, CodeGraph, CodeContrast).

**Bảng 4.** Độ chính xác Top-1 (%) truy xuất văn bản→mã theo Bảng I của [4]

| Kho mã | Loại kiểm tra | Cấu hình D1 / D2 | D2 → D3 |
|---|---|---|---|
| OpenCV | Không tổng hợp ($N = 2813$) | 92,68 / 94,45 | – |
| OpenCV | Tổng hợp ($N = 12\,658$) | – | 66,05 → 80,64 |
| Repo-A (độc quyền) | Không tổng hợp ($N = 3800$) | 74,82 / 79,54 | – |
| Repo-A (độc quyền) | Tổng hợp ($N = 23\,480$) | – | 67,46 → 76,18 |

**Dữ kiện – thực nghiệm và kết quả**

- **Dữ liệu**: Repo-A (mã C của một tổ chức viễn thông, trên 5 triệu dòng, độc quyền) và OpenCV (khoảng 1,2 triệu dòng). CodeScribe dùng Claude Sonnet 4.5; các bước sinh khác dùng Sonnet 4.0.
- **Ba cấu hình dữ liệu**: D1 (phương thức và docstring), D2 (thêm nhận xét tự sinh), D3 (thêm nhận xét cha–anh em và các câu hỏi tổng hợp).
- **Kết quả Top-1**: xem Bảng 4. Theo Bảng II, với OpenCV loại `doc_brief_merged` D2 đạt 96,43% còn D3 đạt 93,94%; các loại câu hỏi tổng hợp (ví dụ `qa_doc_gen`: 57,39% → 78,38%) tăng rõ khi chuyển D2 sang D3.
- **Đánh giá tác tử (RAGAS, LLM làm giám khảo)**: Faithfulness 94,6% (Repo-A) và 93,4% (OpenCV); Answer Correctness có F1 60,0% và 76,4%. Tác giả giải thích Answer Correctness thấp hơn do số lượng khẳng định ít làm mẫu số nhỏ.
- **Chi phí**: sinh tài liệu OpenCV mất khoảng 48 giờ và khoảng 3 200 USD chi phí API; Repo-A khoảng 8 ngày; huấn luyện CodeContrast 4 GPU A100, 15 epoch, khoảng 24 giờ; truy xuất dưới 50 ms mỗi truy vấn, toàn bộ tác tử 3–5 giây mỗi truy vấn.
- **Mối đe dọa tính hợp lệ do tác giả nêu**: chỉ có hai kho (đều C/C++, lập trình hệ thống); phi tất định của LLM và dùng hai phiên bản mô hình; chia tập huấn luyện/kiểm tra theo phương thức nhưng trường cha–anh em có thể tham chiếu mã thuộc tập kiểm tra (đã giảm nhẹ, thay đổi Top-1 dưới 1% trên OpenCV); không thể khẳng định không phụ

thuộc ngôn ngữ; Top-K chỉ là chỉ báo gián tiếp của "hiểu mã"; D3 thêm đồng thời hai nguồn nên không quy được cải thiện cho riêng nguồn nào nếu không loại bỏ từng thành phần; chưa có mô hình tinh chỉnh cho đánh giá tác tử.

**Nhận xét phê phán (diễn giải của nhóm, chưa kiểm chứng độc lập)**

- **Vòng khép kín của đánh giá**: các câu hỏi tổng hợp (loại `qa_*`) được LLM sinh từ chính tài liệu CodeScribe dùng để huấn luyện mô hình truy xuất. Việc D3 tăng Top-1 mạnh trên loại câu hỏi này không cho biết hiệu quả trên câu hỏi do nhà phát triển thực viết; trên câu hỏi gốc (`doc_brief_merged`), D3 thấp hơn D2.
- **Thiếu đường cơ sở bên ngoài**: bài nêu CodeRetriever và CoCoSoDa không có mã cho C/C++ nên so sánh chỉ giữa D1–D3 nội bộ; chưa thấy so sánh với truy xuất bằng mô hình nhúng sẵn có hoặc với truy xuất từ vựng (ví dụ BM25) trong phần đã đọc.
- **Đánh giá tác tử**: ground truth của RAGAS là câu trả lời do LLM sinh cùng lúc sinh câu hỏi; giám khảo là LLM; Faithfulness đo mức bám ngữ cảnh truy xuất, không đo mức đúng so với hành vi thực của mã. Không có kiểm tra thực thi.
- **Sai khác nhỏ trong văn bản**: văn bản nêu Top-1 D2 của Repo-A là 67,6%, còn Bảng I ghi 67,46%; mức tăng 8,72 khớp với 76,18 − 67,46. Sai khác nhỏ, nhưng cho thấy cần đối chiếu bảng khi trích.
- **Khả năng tái lập**: chi phí khoảng 3 200 USD và 48 giờ cho một kho 1,2 triệu dòng, cộng với kho độc quyền, khiến nhóm không thể tái lập đầy đủ trong 3 tuần. Có thể tái dùng ý tưởng: đồ thị gọi hàm tĩnh làm cấu trúc điều hướng ngữ cảnh.
- **Tình trạng bình duyệt**: chưa xác minh.

**Liên hệ với đề tài.** Cho các mục 13.2, 13.5, 13.6, 13.8. Đóng góp có thể tái dùng ở quy mô nhỏ là đồ thị gọi hàm tĩnh làm cơ sở xây dựng ngữ cảnh. Bài cũng cho thấy một khoảng trống: kết quả đo bằng Top-K và giám khảo LLM, chưa có kết quả đo bằng hành vi thực thi của mã.

# I.3. Các công trình bổ sung và kiểm tra tính mới

## I.3.1. Công trình bổ sung đã xác minh trang tóm tắt

**Bảng 5.** Công trình bổ sung (chỉ xác minh trang tóm tắt; số liệu do tác giả công bố)

| Mã | Tên rút gọn | Nội dung chính | Liên hệ với đề tài |
|---|---|---|---|
| [6] | CRUXEval | 800 hàm Python dài 3–13 dòng kèm cặp vào/ra; hai tác vụ dự đoán đầu vào và đầu ra; GPT-4 kèm chain-of-thought đạt 75% (đầu vào) và 81% (đầu ra) pass@1 | Điểm chuẩn nền của [2]; độ nhạy thấp theo [2] |
| [7] | Lost in the Middle | Hai tác vụ (hỏi đáp nhiều tài liệu, truy xuất cặp khóa–giá trị); độ chính xác cao nhất khi thông tin ở đầu hoặc cuối, thấp hơn ở giữa, kể cả mô hình ngữ cảnh dài | Hiệu ứng vị trí trên văn bản; [2] mở rộng sang ngữ nghĩa thực thi của mã |
| [8] | LongCodeZip | Nén ngữ cảnh mã hai tầng (chọn hàm, rồi chọn khối) theo perplexity có điều kiện dưới ngân sách token; tác giả báo cáo nén tới 5,6 lần mà không giảm hiệu năng trên hoàn thành mã, tóm tắt, hỏi đáp | Nén theo mức tương quan, không theo phụ thuộc chương trình; không đo recall ngữ nghĩa theo vị trí |
| [9] | RepoGraph | Mô-đun đồ thị mã cấp kho tích hợp vào các hệ thống kỹ nghệ phần mềm AI; thử trên SWE-bench và CrossCodeEval; tác giả báo cáo cải thiện mọi hệ thống được gắn thêm (tóm tắt không nêu số) | Dùng cấu trúc đồ thị để điều hướng; kết quả theo tác vụ cuối |
| [10] | SWEzze / OCD | Chưng cất ngữ cảnh mã nhỏ nhất đủ dùng bằng tìm kiếm di truyền và delta debugging; nén ổn định khoảng 6 lần, giảm 51,8–71,3% ngân sách token, tăng tỷ lệ giải 5,0–9,2% trên SWE-bench Verified với ba LLM | Bằng chứng rằng rút gọn ngữ cảnh có thể tăng hiệu quả; đo theo tỷ lệ giải issue |
| [11] | Trace Gadgets | Truy vết tĩnh các đường chương trình và cắt lát để chỉ giữ các câu lệnh dẫn tới điểm lỗ hổng; tác giả báo cáo vượt CodeQL ít nhất 4% trên tập chưa thấy | Cắt lát để giảm ngữ cảnh cho dự đoán lỗ hổng, tác vụ khác |
| [12] | Program Slices to Causal Clarity | 93 cấu hình ngữ cảnh gỡ lỗi, ba mô hình; chất lượng giải thích lỗi phụ thuộc thành phần ngữ cảnh; ngữ cảnh rất lớn làm giải thích mơ hồ hơn (EASE '26) | Cho thấy thành phần ngữ cảnh ảnh hưởng chất lượng đầu ra |
| [13] | Completion semantics | Hình thức hóa tính đúng của suy luận LLM trên mã chưa đầy đủ bằng mô hình hoàn thiện ngữ cảnh thiếu; quy trình sinh "chứng cứ" có thể thực thi cho báo cáo lỗi do LLM sinh | Nền tảng lý thuyết về việc mã thiếu ngữ cảnh làm suy luận không xác định |
| [14] | TraceEval | 10 583 chương trình (Python, JS, Java); cạnh gọi hàm được xác nhận bằng thực thi; mô hình tốt nhất trong 10 mô hình đạt F1 trung bình 72,9% | LLM tự khôi phục cấu trúc gọi hàm chưa hoàn hảo, ủng hộ dùng phân tích tĩnh/động |

## I.3.2. Kết quả kiểm tra tính mới

Trong các truy vấn đã chạy (chủ đề: cắt lát chương trình cho ngữ cảnh LLM, hiệu ứng "lost in the middle" với mã, ngữ cảnh phụ thuộc cấu trúc), người soạn thấy:

(a) Cắt lát và rút gọn ngữ cảnh mã đã được dùng cho dự đoán lỗ hổng [11], sửa lỗi và giải quyết issue [10], giải thích lỗi [12], nén ngữ cảnh [8]. Do đó ý tưởng chung "rút gọn ngữ cảnh bằng phân tích chương trình có ích" **không mới**.

(b) Chưa tìm thấy công trình nào cùng lúc (i) đo riêng *semantic recall* theo vị trí mã trong ngữ cảnh, (ii) so sánh có kiểm soát giữa độ dài ngữ cảnh, việc chọn mã và việc sắp xếp thứ tự, (iii) dùng hàm gây nhiễu có cấu trúc giống hàm đích, và (iv) kiểm chứng đầu ra bằng thực thi. Phát hiện này giới hạn ở các truy vấn đã chạy.

(c) [2] chỉ chẩn đoán hiện tượng và nêu rõ hàm gây nhiễu liên quan ngữ nghĩa là câu hỏi mở; đây là chỗ đề tài có thể đóng góp.

**Nhận xét phê phán (diễn giải của nhóm, chưa kiểm chứng độc lập)**

Tính mới của đề tài (nếu có) nằm ở thiết kế đối chứng tách các nguyên nhân (độ dài, chọn lọc, thứ tự), không nằm ở ý tưởng dùng phân tích chương trình để rút gọn ngữ cảnh. Nhóm không nên viết "đề xuất rút gọn ngữ cảnh bằng cắt lát" như một đóng góp mới. Cần thêm truy vấn trên arXiv, Semantic Scholar và Google Scholar trước khi khẳng định tính mới trong bài.

# I.4. Ánh xạ sang nội dung Chương 13 của đề cương học phần

**Bảng 6.** Mức độ bao phủ các mục 13.1–13.11 bởi bốn bài báo

| Mục của đề cương | Bài liên quan | Mức bao phủ (đánh giá của người soạn) |
|---|---|---|
| 13.1 Biểu diễn, mã hóa mã nguồn | [1] | Có bảng tổng hợp tokenizer của các LLM cho mã; không có bài nào phân tích sâu |
| 13.2 Biểu diễn nhúng | [4],[1] | Bộ mã hóa kép đối sánh trong [4] |
| 13.3 Tóm tắt, giải thích mã | [1],[4] | 41 nghiên cứu tóm tắt trong [1]; tài liệu phân cấp trong [4] |
| 13.4 Sinh mã từ ngôn ngữ tự nhiên | [1] | Chỉ ở mức khảo sát |
| 13.5 Mã → mô tả ngôn ngữ tự nhiên | [4] | CodeScribe |
| 13.6 Tìm kiếm, hiểu mã cấp kho | [4],[1] | Đủ cho ví dụ cấp kho; thực nghiệm giới hạn ở C/C++ |
| 13.7 Suy luận nhiều bước | [2] | Dự đoán đầu ra là suy luận thực thi tuần tự |
| 13.8 Hiểu mã tăng cường bằng truy xuất | [4] | Truy xuất kèm tác tử; không có đối chứng với không truy xuất |
| 13.9 Thiết kế lời nhắc | [2] | Mỏng: chỉ có việc đặt câu hỏi trước và sau mã |
| 13.10 Bịa đặt và giới hạn cửa sổ ngữ cảnh | [2],[4],[3] | [2] là bằng chứng thực nghiệm chính; [3] bàn về độ tin cậy |
| 13.11 Giới hạn của LLM trong suy luận mã | [2],[3] | Có, nhưng chủ yếu từ [2] |

**Nhận xét phê phán (diễn giải của nhóm, chưa kiểm chứng độc lập)**

Các mục 13.10 và 13.11 được phủ tốt nhất bằng thực nghiệm ([2]), và là mục duy nhất trong bốn bài có thể kiểm chứng lại với chi phí thấp. Mục 13.9 được phủ yếu; nếu chọn hướng đề xuất ở Phần II, nhóm cần tìm thêm tài liệu về thiết kế lời nhắc.

# I.5. Tổng hợp và so sánh

**Bảng 7.** So sánh bốn bài về loại bằng chứng và độ tin cậy (xếp loại do người soạn)

| Tiêu chí | [1] | [2] | [3] | [4] |
|---|---|---|---|---|
| Loại bằng chứng (theo thang E1–E4 của [3]) | Tổng hợp tài liệu | E2 (điểm chuẩn có kiểm soát, đối chứng bằng cách bỏ dòng) | Tổng hợp có cấu trúc | E2–E3 cục bộ (hai kho mã; không có kiểm thử thực thi) |
| Đối chứng/loại bỏ thành phần | Không áp dụng | Có (bỏ dòng, thay đổi số chữ số, thay ngôn ngữ) | Không áp dụng | Chỉ D1–D3 nội bộ, D3 gộp hai nguồn |
| Độ tái lập dự kiến với nhóm | Cao (kho trực tuyến) | Cao với phần sinh dữ liệu; phụ thuộc ngân sách cho chạy mô hình | Cao (đọc) | Thấp (chi phí, kho độc quyền) |
| Rủi ro chính | Lỗi thời (08/2024) | Mô hình và ngữ cảnh đã cũ; hàm gây nhiễu ngẫu nhiên | Chọn nguồn theo trích dẫn; chưa xác nhận khung | Đánh giá khép kín; không đường cơ sở ngoài |

**Điểm bổ sung giữa các bài.** [2] cho thấy mô hình có thể truy xuất đúng mã nhưng không dùng đúng ngữ nghĩa của mã khi ngữ cảnh dài; [4] xây dựng cách chọn mã liên quan ở quy mô kho nhưng đo kết quả bằng chỉ báo gián tiếp; [3] cho khung để báo cáo và giới hạn tuyên bố. Hai bài đầu có điểm giao: chọn đúng mã ([4]) không đảm bảo mô hình dùng đúng ngữ nghĩa của mã đó ([2]).

**Điểm có thể mâu thuẫn hoặc chưa thống nhất.** [4] xem việc đưa toàn bộ kho vào ngữ cảnh là không nên (dựa trên chi phí và kết quả kém hơn của ngữ cảnh lớn), trong khi [2] cho thấy ngay ở 4 k token đã có suy giảm với semantic recall. Hai nhận định tương thích nhau, nhưng chỉ có [2] có đối chứng trực tiếp; nhận định trong [4] được dẫn từ tài liệu khác.

**Khoảng trống chung.** Chưa bài nào trong bốn bài (i) đo tác động của việc *chọn và sắp xếp* ngữ cảnh lên semantic recall bằng đối chứng, (ii) kết hợp bằng chứng thực thi để kiểm tra đầu ra của LLM, hoặc (iii) kiểm tra với hàm gây nhiễu có cấu trúc giống hàm đích. Đây là cơ sở cho Phần II.

# Phần II.
# Đề cương nghiên cứu chi tiết

**Trạng thái của Phần II**

Phần II là đề xuất của người soạn dựa trên các bài đã đọc ở Phần I. Chưa có thực nghiệm nào được chạy: bộ sinh dữ liệu, bộ dựng ngữ cảnh và các giả thuyết chưa được kiểm tra. Hướng đề tài, tên đề tài, ngưỡng quyết định và phân công cần nhóm xác nhận (và, với hướng đề tài, nên được giảng viên xác nhận) trước khi triển khai.

## II.1. Thông tin chung

**Bảng 8.** Thông tin chung của đề cương

| | |
|---|---|
| Học phần | IT5440 – Nguyên lý và kỹ thuật phân tích chương trình, kỳ 2026.1 |
| Giảng viên | PGS. TS. Huỳnh Quyết Thắng |
| Đề tài đã đăng ký | 5-KH, Chương 13: Mô hình ngôn ngữ lớn cho hiểu mã nguồn và phân tích chương trình |
| Hướng thực hiện | Nghiên cứu khoa học (KH) |
| Nhóm | KHMT 2: Nguyễn Tiến Luyện (trưởng nhóm), Nguyễn Đức Thịnh, Nguyễn Ngọc Tuấn, Vũ Ngọc Vinh, Lattana Aphixay, Trần Thanh Lâm, Nguyễn Văn Hiếu |
| Thời gian | Từ 05/11/2026; báo cáo lần 1 ngày 18–19/11; lần 2 ngày 25–26/11; hoàn thành trong tháng 12/2026 (ngày cụ thể chưa có) |
| Sản phẩm cuối | Báo cáo đầy đủ, báo cáo tóm tắt dạng bài báo (đủ điều kiện đăng arXiv), slide, mã nguồn và dữ liệu |
| Mục tiêu điểm | Mức A (8,5–10) theo hướng dẫn: bài báo hoàn thành, đủ điều kiện công bố |

## II.2. Tên đề tài đề xuất

**Tên tiếng Việt (tạm thời):** Dựng ngữ cảnh dựa trên phân tích chương trình để khôi phục khả năng hiểu ngữ nghĩa thực thi của mô hình ngôn ngữ lớn trên mã nguồn trong ngữ cảnh dài: nghiên cứu thực nghiệm có đối chứng.

**Tên tiếng Anh (tạm thời):** Program-Analysis-Guided Context Construction for Semantic Code Understanding in Long Contexts: A Controlled Empirical Study.

**Nhận xét phê phán (diễn giải của nhóm, chưa kiểm chứng độc lập)**

Tên đề tài ngầm giả định rằng việc dựng ngữ cảnh bằng phân tích chương trình *có* khôi phục khả năng hiểu ngữ nghĩa. Đây là giả thuyết cần kiểm chứng, chưa phải kết quả. Nếu thực nghiệm cho thấy chỉ sắp xếp lại thứ tự đã đủ (xem H2 ở mục II.6), tên đề tài phải đổi, ví dụ thành "Vị trí và chọn lọc ngữ cảnh trong hiểu ngữ nghĩa mã nguồn". Đề cương đã được thiết kế để kết quả âm tính vẫn công bố được.

# II.3. Tóm tắt

## II.3.1. Tóm tắt (tiếng Việt)

Các mô hình ngôn ngữ lớn (LLM) có thể truy xuất đúng một hàm trong ngữ cảnh dài nhưng dự đoán sai kết quả thực thi của hàm đó khi hàm nằm ở giữa ngữ cảnh [2]. Công trình đó chỉ chẩn đoán hiện tượng, dùng hàm gây nhiễu ngẫu nhiên, ngữ cảnh tối đa khoảng 16 k token và các mô hình thuộc giai đoạn 2024–2025. Nghiên cứu này dự kiến (i) kiểm tra liệu hiệu ứng có còn với các mô hình hiện hành và ngữ cảnh dài hơn (RQ1); (ii) xây dựng bộ dữ liệu sinh tự động SemTrace-Dep, trong đó mã cần thiết gồm nhiều hàm phụ thuộc nhau, nằm rải rác giữa các hàm gây nhiễu có cấu trúc giống hàm đích, và so sánh có đối chứng ngữ cảnh dài thô, ngữ cảnh sắp xếp lại, ngữ cảnh dựng bằng bao đóng đồ thị gọi hàm tĩnh và truy xuất bằng biểu diễn nhúng, nhằm tách phần cải thiện do sắp xếp, độ dài và chọn đúng mã (RQ2); (iii) đo khả năng và chi phí của kiểm chứng bằng thực thi so với giám khảo LLM và biểu quyết tự nhất quán (RQ3). Hướng đánh giá theo kiểu thực nghiệm có đối chứng, giả thuyết và tiêu chí bác bỏ được ghi trước khi chạy, và báo cáo theo quy trình tối thiểu của [3]. Tại thời điểm viết, chưa có kết quả thực nghiệm.

## II.3.2. Abstract (English, proposal stage)

Large language models (LLMs) can retrieve a function from a long code context yet mispredict its execution result when the function lies in the middle of the context [2]. That work diagnoses the effect using random distractors, contexts of up to about 16k tokens, and 2024–2025 models. We plan to (i) test whether the effect persists for current models and longer contexts (RQ1); (ii) build SemTrace-Dep, a generated benchmark in which the needed code consists of several interdependent functions scattered among structurally similar distractors, and compare raw long context, reordered context, static call-graph closure, and embedding retrieval to separate the contributions of ordering, length, and selection (RQ2); and (iii) measure the effectiveness and cost of execution-based verification against LLM-as-judge and self-consistency (RQ3). Hypotheses and refutation criteria are fixed before the test runs, and reporting follows the

minimum protocol of [3]. No experimental results exist at the proposal stage.

# II.4. Bối cảnh, động cơ và phát biểu vấn đề

## II.4.1. Bối cảnh

Học phần nhấn mạnh rằng LLM hỗ trợ sinh mã và giải thích mã, nhưng chỉ phân tích chương trình mới cung cấp bằng chứng độc lập để xác nhận tính đúng của kết quả. Trong thực tế, LLM được dùng để hiểu kho mã lớn bằng cách đưa vào ngữ cảnh nhiều mã, hoặc dùng truy xuất để chọn mã liên quan [4, 9]. Các hệ thống cấp kho mã thường chọn mã theo mức tương đồng văn bản hoặc theo cấu trúc đồ thị [4, 9, 8], và được đánh giá bằng tỷ lệ truy xuất đúng, tỷ lệ giải issue hoặc giám khảo LLM, chưa đánh giá bằng việc mô hình có dùng đúng ngữ nghĩa thực thi của mã được cung cấp hay không.

## II.4.2. Vấn đề

[2] chỉ ra rằng khả năng truy xuất đúng mã (lexical recall) và khả năng dùng đúng ngữ nghĩa của mã (semantic recall) tách rời nhau: lexical recall ổn định theo vị trí, semantic recall suy giảm khi mã ở giữa. Câu hỏi thực tiễn tiếp theo, [2] chưa trả lời, là: có thể làm gì với phần ngữ cảnh được cung cấp để giảm suy giảm đó, và biện pháp nào có hiệu quả (sắp xếp lại, rút ngắn, chọn đúng mã theo phụ thuộc chương trình)?

## II.4.3. Phát biểu bài toán hình thức

Cho một cơ sở mã $\mathcal{K}$ gồm tập hàm $\{g_j\}$ với quan hệ gọi hàm; một hàm đích $f \in \mathcal{K}$ và đầu vào $x$. Gọi $\mathcal{N}(f)$ là tập các hàm có thể được gọi (trực tiếp hoặc gián tiếp) khi thực thi $f$. Đầu ra đúng là $y = \text{exec}(f, x)$. Một *điều kiện ngữ cảnh* $c$ ánh xạ $(\mathcal{K}, f, x)$ thành một chuỗi mã $K_c$ đưa vào LLM cùng câu hỏi "$f(x)$ trả về gì?". Mục tiêu là so sánh độ chính xác $\Pr[\hat{y} = y]$ giữa các điều kiện $c$ khi $K_c$ có độ dài, nội dung và thứ tự khác nhau, với $\mathcal{N}(f)$ không đổi.

# II.5. Tổng quan tóm tắt và khoảng trống nghiên cứu

Chi tiết các công trình nằm ở Phần I. Bảng 9 tóm tắt các khoảng trống, mỗi khoảng trống kèm bằng chứng và mức chắc chắn.

**Bảng 9.** Khoảng trống nghiên cứu, bằng chứng và mức chắc chắn

| Mã | Khoảng trống | Bằng chứng | Mức chắc chắn |
|---|---|---|---|
| G1 | Hiệu ứng suy giảm semantic recall chỉ được chẩn đoán trên 10 mô hình thế hệ 2024–2025, ngữ cảnh tối đa khoảng 16 k token, hàm gây nhiễu ngẫu nhiên; không thử biện pháp giảm nhẹ | Phương pháp và hạn chế do tác giả nêu [2] | Cao (dữ kiện từ bài) |
| G2 | Các phương pháp nén/chọn ngữ cảnh mã [8, 10, 9] được đánh giá bằng hiệu năng tác vụ cuối (hoàn thành mã, hỏi đáp, giải issue); chưa tách đóng góp của độ dài, chọn lọc và thứ tự, và chưa đo semantic recall | Tóm tắt của các bài; người soạn chưa đọc toàn văn | Trung bình (suy ra từ tóm tắt) |
| G3 | Đồ thị gọi hàm tĩnh dùng để điều hướng ngữ cảnh [4], nhưng kết quả đo bằng Top-K và giám khảo LLM; chưa có kiểm tra bằng thực thi | Phân tích Phần I mục I.2.4 | Trung bình đến cao |
| G4 | Hàm gây nhiễu liên quan ngữ nghĩa (giống cấu trúc hàm đích) chưa được đánh giá | Hạn chế (1) do [2] nêu | Cao |
| G5 | Báo cáo thực nghiệm LLM-mã thường thiếu đối chứng loại bỏ thành phần, ngân sách cân bằng, lặp lại; [3] đề xuất quy trình tối thiểu | Phân tích của [3]; chưa xác minh độc lập | Trung bình |

**Nhận xét phê phán (diễn giải của nhóm, chưa kiểm chứng độc lập)**

G2 là suy luận từ trang tóm tắt, không phải từ toàn văn: các bài có thể có phân tích ablation mà tóm tắt không nêu. Nhóm cần đọc toàn văn [8], [10] và [9] trước khi viết khoảng trống G2 vào bài.

# II.6. Mục tiêu, giả thuyết và câu hỏi nghiên cứu

## II.6.1. Mục tiêu

1. Xác định mức độ tồn tại của hiệu ứng suy giảm semantic recall với mô hình hiện hành và ngữ cảnh dài hơn.
2. Xây dựng bộ dữ liệu sinh tự động có đối chứng để đo hiệu ứng khi mã cần thiết gồm nhiều hàm phụ thuộc.
3. Tách đóng góp của sắp xếp, độ dài và chọn đúng mã vào việc khôi phục semantic recall.
4. Đo chi phí và hiệu quả kiểm chứng bằng thực thi so với các lựa chọn không dùng bằng chứng thực thi.

## II.6.2. Câu hỏi nghiên cứu và giả thuyết

**Bảng 10.** Câu hỏi nghiên cứu, giả thuyết, tiêu chí bác bỏ và liên hệ với đề cương học phần

| Mã | Câu hỏi nghiên cứu | Giả thuyết và tiêu chí bác bỏ (ngưỡng đề xuất, nhóm chốt trước khi chạy) | Mục 13.x |
|---|---|---|---|
| RQ1 | Hiệu ứng suy giảm semantic recall khi mã đích ở giữa ngữ cảnh dài có còn với mô hình hiện hành không? Biên độ thay đổi thế nào theo độ dài ngữ cảnh và độ khó (số chữ số)? | **H1**: với ít nhất hai trong ba mô hình, ở $L = 16\,\text{k}$ token trên SemTrace 4 chữ số, biên độ vị trí $A \geq 15$ điểm phần trăm, trong khi lexical recall $\geq 95\%$. Bác bỏ nếu cận trên khoảng tin cậy 95% của $A$ nhỏ hơn 5 điểm phần trăm với mọi mô hình. Khoảng giữa hai ngưỡng: không kết luận. | 13.10, 13.11 |
| RQ2 | Với mã cần thiết gồm nhiều hàm phụ thuộc, rải rác giữa hàm gây nhiễu có cấu trúc giống, ngữ cảnh dựng bằng bao đóng đồ thị gọi hàm tĩnh có khôi phục semantic recall so với ngữ cảnh dài thô và truy xuất nhúng không? Phần cải thiện chia thế nào cho sắp xếp lại, giảm độ dài và chọn đúng mã? | **H2**: ở $L = 16\,\text{k}$, vị trí giữa, $\text{Acc}(C3) - \text{Acc}(C1) \geq 15$ điểm phần trăm với ít nhất hai mô hình. Bác bỏ nếu hiệu này có cận trên khoảng tin cậy dưới 5 điểm phần trăm.<br>**Phân rã (mô tả, không ngưỡng)**: tỷ lệ $(\text{Acc}(C2) - \text{Acc}(C1))/(\text{Acc}(C3) - \text{Acc}(C1))$ cho biết mức cải thiện do sắp xếp lại. | 13.6, 13.7, 13.8 |
| RQ3 | Với các dự đoán sai còn lại, kiểm chứng bằng thực thi phát hiện và sửa được bao nhiêu so với giám khảo LLM không thực thi và biểu quyết tự nhất quán, ở chi phí token nào? | **H3**: giám khảo LLM không thực thi chấp nhận sai ít nhất 15% các dự đoán sai (cận dưới khoảng tin cậy trên 10%). Bác bỏ nếu cận trên dưới 5%. Kiểm chứng bằng thực thi chỉ đạt độ chính xác cao do đặc điểm của bộ dữ liệu (xem mục II.8.7); H3 không dùng để khẳng định lợi ích thực tế. | Thông điệp học phần; liên quan Chương 14 |

**Nhận xét phê phán (diễn giải của nhóm, chưa kiểm chứng độc lập)**

- Các ngưỡng 15, 10, 5 điểm phần trăm và 95% là đề xuất, chọn để khớp với năng lực thống kê ở mục II.8.6; không có cơ sở từ tài liệu. Nhóm cần chốt (và ghi vào kho mã trước khi chạy tập kiểm tra) để tránh chọn ngưỡng sau khi thấy dữ liệu.
- RQ3 gần như tầm thường trên bộ dữ liệu này: nếu có thể thực thi hàm với đầu vào cho trước, câu trả lời đúng có ngay mà không cần LLM. RQ3 chỉ có ý nghĩa như phép kiểm tra thông điệp của học phần ở mức bằng chứng E2 [3]; ưu tiên thấp nhất và có thể cắt nếu thiếu thời gian.
- RQ2 có thể cho kết quả mà việc sắp xếp lại đã đủ giải thích gần hết cải thiện. Khi đó

phân tích chương trình chỉ đóng góp ở việc *xác định* mã cần sắp xếp; kết quả vẫn công bố được nhưng thông điệp khác với tên đề tài đề xuất.

- Có thể thêm RQ4 (chuyển sang mã thực từ kho mã mã nguồn mở có kiểm thử) làm phần mở rộng; không cam kết trong 3 tuần.

# II.7. Đóng góp dự kiến và triết lý khoa học

## II.7.1. Đóng góp dự kiến

1. **Bộ dữ liệu SemTrace-Dep** (đặc tả, bộ sinh theo hạt giống ngẫu nhiên, mã nguồn): mở rộng SemTrace [2] sang mã cần thiết gồm nhiều hàm phụ thuộc, hàm gây nhiễu giống cấu trúc. Điều kiện kiểm chứng: bộ sinh được kiểm chéo bằng hai bộ đánh giá độc lập, và có tài liệu đặc tả.
2. **Phân rã thực nghiệm** đóng góp của sắp xếp, độ dài và chọn mã vào semantic recall bằng các đối chiếu được ghi trước (mục II.8.4). Điều kiện kiểm chứng: báo cáo kèm khoảng tin cậy và nhiều mô hình.
3. **Kiểm tra lại hiệu ứng suy giảm theo vị trí** với mô hình hiện hành và ngữ cảnh dài hơn [2]: kết quả dương hay âm đều là đóng góp.
4. **Gói tái lập** theo quy trình báo cáo tối thiểu của [3]: cấu hình, nhật ký lời nhắc và đầu ra, hạt giống.

**Nhận xét phê phán (diễn giải của nhóm, chưa kiểm chứng độc lập)**

Không nên ghi "phương pháp cắt lát/bao đóng đồ thị gọi hàm" làm đóng góp phương pháp mới: ý tưởng chung đã có (mục I.3, các bài [11, 10, 12]). Đóng góp 3 phụ thuộc vào việc nhóm tái lập được số liệu cơ sở của [2] (mục II.11.1); nếu không tái lập được bảng cơ sở, nhóm phải báo cáo điều đó thay vì tiếp tục.

## II.7.2. Triết lý khoa học áp dụng

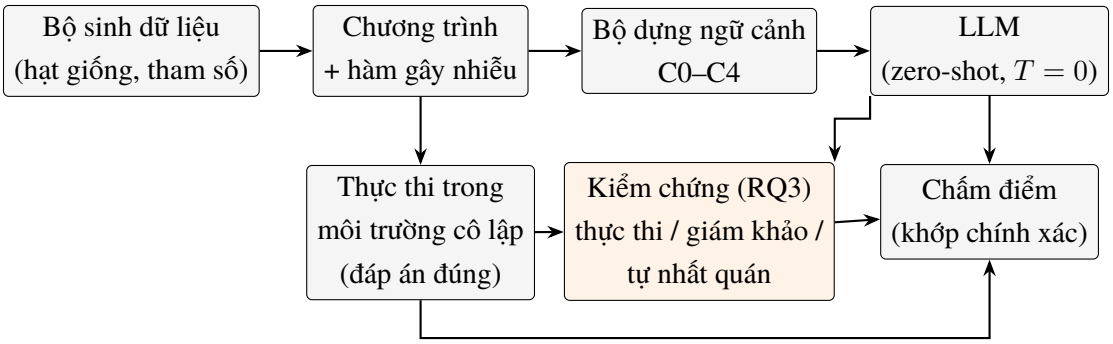
Hướng dẫn yêu cầu làm rõ triết lý khoa học nhưng không định nghĩa. Đề xuất cách trình bày gồm bốn nguyên tắc; đây là diễn giải của người soạn:

1. **Giả thuyết có thể bị bác bỏ** (theo tinh thần của chủ nghĩa duy lý phê phán [15]): mỗi RQ có giả thuyết, ngưỡng bác bỏ và kết quả có thể sai được; ngưỡng ghi trước khi chạy.
2. **Đối chứng và phản chứng bằng can thiệp**: thay đổi từng nhân tố (thứ tự, độ dài, chọn mã) trong khi giữ các nhân tố khác, cùng tinh thần với phép bỏ dòng lệnh trong [2].

3. **Tuyên bố tương xứng với bằng chứng**: chỉ tuyên bố ở mức E2 (điểm chuẩn có kiểm soát) theo [3], không khái quát lên hiệu quả trên kho mã thực.
4. **Minh bạch và tái lập**: công bố cả kết quả âm tính, cấu hình và nhật ký; phân biệt dữ kiện, diễn giải và ý kiến.

# II.8. Phương pháp nghiên cứu

## II.8.1. Thiết kế tổng thể




**Hình 1.** Sơ đồ thiết kế thực nghiệm (đề xuất; chưa cài đặt)

## II.8.2. Định nghĩa và chỉ số

Với mô hình $m$, điều kiện ngữ cảnh $c$, độ dài ngữ cảnh $L$ (số token) và vị trí tương đối $p \in [0, 1]$ của mã cần thiết, độ chính xác khớp chính xác trên $n$ mục là

$$\mathrm{Acc}(m, c, L, p) = \frac{1}{n} \sum_{i=1}^{n} \mathbb{1}\big[\hat{y}_i = y_i\big]. \tag{2}$$

Biên độ vị trí và mức giảm ở giữa được định nghĩa:

$$A(m, c, L) = \max_{p} \mathrm{Acc}(m, c, L, p) - \min_{p} \mathrm{Acc}(m, c, L, p), \tag{3}$$

$$D(m, c, L) = \frac{\mathrm{Acc}(m, c, L, 0) + \mathrm{Acc}(m, c, L, 1)}{2} - \mathrm{Acc}(m, c, L, 0{,}5). \tag{4}$$

Để so sánh với [2], nhóm sẽ báo cáo thêm thay đổi tương đối so với cực đại theo vị trí,

$$\Delta_{\mathrm{rel}}(m, c, L, p) = \frac{\mathrm{Acc}(m, c, L, p) - \max_{p'} \mathrm{Acc}(m, c, L, p')}{\max_{p'} \mathrm{Acc}(m, c, L, p')} \times 100\%, \tag{5}$$

cùng với mức giảm tuyệt đối theo điểm phần trăm. Định nghĩa phương trình (5) là cách hiểu của người soạn về thay đổi tương đối trong [2], có thể khác chi tiết của bài; cần đối chiếu với mã nguồn của tác giả. Với điều kiện có chọn mã, độ phủ mã cần thiết là

$$\mathrm{Cov}(c) = \frac{|K_c \cap \mathcal{N}(f)|}{|\mathcal{N}(f)|}, \tag{6}$$

và độ tinh khiết là tỷ lệ số hàm trong $K_c$ thuộc $\mathcal{N}(f) \cup \{f\}$. Ngoài ra ghi nhận số token đầu vào và đầu ra, và độ trễ.

## II.8.3. Bộ dữ liệu

**Bảng 11.** Các bộ dữ liệu và mức ưu tiên

| Mã | Tên | Mô tả | Ưu tiên |
|---|---|---|---|
| D1 | SemTrace-3/4 (cài đặt lại) | Cài đặt lại SemTrace [2] từ mô tả của bài với phép cộng/trừ 3 và 4 chữ số (tránh ghi nhớ số học hai chữ số); kèm tác vụ truy xuất hàm (lexical recall) | P0 |
| D2 | SemTrace-Dep (mới) | Hàm đích $f$ gọi $k$ hàm phụ thuộc theo độ sâu $d$; mỗi hàm gồm $m$ phép cộng/trừ với hằng số ba chữ số ngẫu nhiên, tên định danh ngẫu nhiên; hàm gây nhiễu hai loại: ngẫu nhiên không liên quan, và giống cấu trúc (cùng mẫu, khác hằng số, không được gọi); mã cần thiết đặt liền khối hoặc rải rác | P0 |
| D3 | Tập con CRUXEval [6] | Điểm chuẩn có độ nhạy thấp theo [2], dùng làm đối chứng; cần kiểm tra giấy phép và sự sẵn có | P1 |
| D4 | Mở rộng JavaScript | Dịch D2 sang JavaScript (phân tích tĩnh bằng Tree-sitter) | P2 |

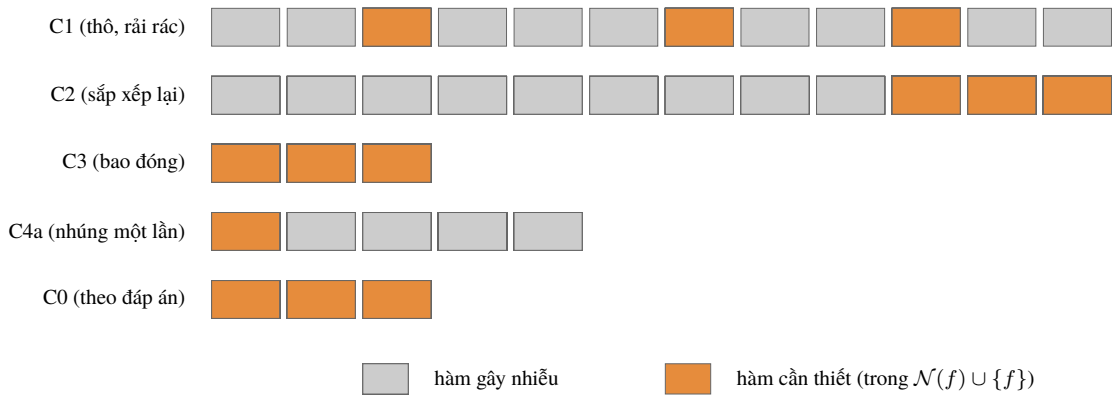
**Tham số mặc định của D2 (đề xuất):** $k \in \{3, 5\}$, $d \in \{1, 2\}$, $m = 3$, hằng số trong $[100, 999]$ với dấu ngẫu nhiên, độ dài $L \in \{4\text{k}, 16\text{k}\}$ token ở mức P0 (thêm 32k ở P1), vị trí $p \in \{0; 0{,}5; 1\}$ ở P0 (năm vị trí ở P1). Hàm gây nhiễu ngẫu nhiên dùng các hàm Python tổng quát (nguồn dùng cần kiểm tra giấy phép trước khi tái phân phối; [2] dùng CodeSearchNet-Python). Ví dụ minh họa nằm ở Phụ lục A.

**Đáp án đúng** lấy bằng thực thi trong môi trường cô lập. Để phát hiện lỗi của bộ sinh, đáp án được đối chiếu với một bộ đánh giá thứ hai viết độc lập (bộ thông dịch biểu thức dựa trên cây cú pháp), và mọi mục không khớp bị loại và ghi nhật ký.

## II.8.4. Các điều kiện ngữ cảnh

**Bảng 12.** Các điều kiện ngữ cảnh

| Mã | Tên | Định nghĩa |
|---|---|---|
| C0 | Tối thiểu theo đáp án | Chỉ $f$ và $\mathcal{N}(f)$ lấy từ đáp án của bộ sinh (không phân tích), thứ tự callee trước caller, không hàm gây nhiễu; cận trên ở chế độ chọn mã hoàn hảo |
| C1 | Dài thô | Toàn bộ mã gồm hàm gây nhiễu; mã cần thiết ở vị trí tương đối $p$ (liền khối hoặc rải rác) |
| C2 | Sắp xếp lại | Cùng nội dung và độ dài như C1 nhưng gom mã cần thiết thành một khối liền ở cuối ngữ cảnh (trước câu hỏi), theo thứ tự phụ thuộc; hàm gây nhiễu giữ phía trước |
| C3 | Bao đóng đồ thị gọi hàm | Phân tích cú pháp (cây cú pháp trừu tượng) xây đồ thị gọi hàm tĩnh theo tên; ngữ cảnh gồm $f$ và các hàm đạt tới từ $f$, callee trước caller, không hàm gây nhiễu |
| C4a | Truy xuất nhúng một lần | Chia ngữ cảnh dài thành khối theo hàm, nhúng bằng mô hình nhúng mã mở (do nhóm chọn), lấy $k_r$ khối gần nhất với câu hỏi |
| C4b | Truy xuất nhúng lặp (P1) | Như C4a, nhưng sau mỗi lượt, tra cứu các tên hàm xuất hiện trong khối vừa lấy rồi lấy tiếp |




**Hình 2.** Minh họa bố cục ngữ cảnh theo điều kiện (hình ví dụ; số khối không phản ánh số liệu thực). C4a minh họa trường hợp truy xuất bỏ sót hai hàm cần thiết và lấy nhầm bốn hàm gây nhiễu.

**Các đối chiếu được ghi trước** (tối đa 5, hiệu chỉnh Holm):

K1: C1 ($p = 0{,}5$) so với C1 ($p \in \{0, 1\}$): hiệu ứng vị trí (RQ1).

K2: C1 so với C2 (rải rác): ảnh hưởng của việc gom và sắp xếp ở cùng nội dung và độ dài.

K3: C2 so với C0: ảnh hưởng của việc có thêm hàm gây nhiễu khi thứ tự đã thuận lợi (độ dài).

K4: C3 so với C0: tổn thất do phân tích tĩnh không hoàn hảo (giá trị âm cho thấy bỏ sót hoặc thêm thừa).

K5: C3 so với C1 và C3 so với C4a: lợi ích tổng thể của chọn lọc theo phụ thuộc chương trình so với ngữ cảnh thô và so với truy xuất theo tương đồng (RQ2).

**Nhận xét phê phán (diễn giải của nhóm, chưa kiểm chứng độc lập)**

- **Điểm yếu của C4a**: trong D2, truy vấn nêu tên hàm đích và đầu vào nhưng không nêu tên các hàm phụ thuộc, nên truy xuất theo tương đồng một lần có thể bỏ sót hàm cần thiết. Đây là đặc trưng có chủ ý của thiết kế nhưng có thể bị xem là đường cơ sở yếu; C4b được thêm để giảm rủi ro này.
- **C3 trên mã tổng hợp có thể quá dễ**: đồ thị gọi hàm tĩnh theo tên trong mã sinh tự động hầu như chính xác. Để C3 không được thuận lợi giả tạo, P1 cần thêm biến thể gọi gián tiếp (hàm truyền như tham số, tra cứu qua từ điển) mà phân tích tĩnh theo tên bỏ sót. [14] cho thấy LLM khôi phục cấu trúc gọi hàm chưa hoàn hảo, và các tình huống động là nơi phân tích tĩnh cũng có giới hạn.
- **Ngữ cảnh ngắn và dài đồng thời thay đổi**: C3 khác C1 ở cả độ dài, chọn mã và thứ tự; chính vì vậy cần C2 và C0 để phân rã, và kết luận về từng nhân tố chỉ hợp lệ trong phạm vi các đối chiếu K1–K5.

## II.8.5. Mô hình và lời nhắc

- **Mô hình**: tối thiểu ba, gồm ít nhất một mô hình thuộc danh sách của [2] làm mốc kiểm tra tái lập (ví dụ một biến thể Qwen 2.5 Coder hoặc Llama 3.x) và ít nhất một mô hình hiện hành không có trong [2]. Danh sách cuối cùng chỉ chốt sau khi biết ngân sách, hạn mức API và phần cứng; người soạn không có thông tin này, và không xác minh được mô hình nào hiện sẵn có.
- **Lời nhắc**: đặt câu hỏi cả trước và sau mã như trong [2]; yêu cầu đầu ra là một literal Python; không dùng ví dụ mẫu; giải mã tham lam ($T = 0$) với mô hình mở; ghi phiên bản và ngày của mô hình thương mại. Khuôn mẫu ở Phụ lục B.
- **Biến thể P1**: có và không có suy luận từng bước, vì suy luận từng bước làm thay đổi chi phí token và có thể giảm hiệu ứng.
- **Tập phát triển và tập kiểm tra**: lời nhắc và bộ phân tích đầu ra được chỉnh trên tập phát triển (hạt giống riêng); tập kiểm tra dùng hạt giống khác và chỉ chạy sau khi đóng băng cấu hình.

### II.8.6. Thiết kế thống kê

- **Cỡ mẫu**: $n = 200$ mục cho mỗi ô (mô hình $\times$ điều kiện $\times$ độ dài $\times$ vị trí). Theo xấp xỉ chuẩn cho hai tỷ lệ độc lập (mức ý nghĩa 5%, hiệu lực 80%): cần khoảng 385 mục mỗi nhóm để phát hiện chênh lệch 10 điểm phần trăm quanh mức 50%; khoảng 167 mục cho chênh lệch 15 điểm phần trăm quanh 50% (50% so với 65%); khoảng 160 mục cho chênh lệch từ 30% lên 45%. Do đó $n = 200$ phù hợp cho hiệu ứng từ khoảng 15 điểm phần trăm, không đủ cho 10 điểm phần trăm. Thiết kế ghép cặp (cùng một mục dưới nhiều điều kiện) thường tăng hiệu lực nhưng chưa được tính ở đây.
- **Ước lượng**: khoảng tin cậy 95% bằng bootstrap theo mục (10 000 lần lấy mẫu lại).
- **So sánh có ghép cặp**: kiểm định McNemar chính xác hoặc bootstrap ghép cặp cho hiệu độ chính xác giữa hai điều kiện trên cùng tập mục.
- **Đa so sánh**: hiệu chỉnh Holm trên tập đối chiếu K1–K5 cho từng mô hình; báo cáo cả kích thước hiệu ứng.
- **Tính không tất định**: với mô hình thương mại, đầu ra có thể khác nhau giữa các lần gọi dù $T = 0$; chạy lặp ít nhất hai lần trên một tập con và báo cáo mức khác nhau.
- **Phân tích sai**: gán nguyên nhân cho từng dự đoán sai bằng cách đối chiếu với đầu ra của các chương trình phản thực (bỏ một hàm phụ thuộc, hoặc thay hằng số) để xem dự đoán khớp với kịch bản nào, theo tinh thần phép đối chứng của [2].

### II.8.7. Kiểm chứng bằng thực thi (RQ3)

Ba bộ kiểm chứng được so sánh ở ngân sách token cân bằng:

1. $V_{\text{exec}}$: chạy $f(x)$ cùng $K_{C3}$ trong môi trường cô lập (không mạng, giới hạn thời gian và bộ nhớ), so sánh với dự đoán; nếu khác, đưa giá trị thực thi và dấu vết vào lượt thử lại, tối đa hai lần.
2. $V_{\text{judge}}$: LLM nhận ngữ cảnh và dự đoán, trả lời đúng/sai, không thực thi.
3. $V_{\text{sc}}$: biểu quyết đa số trên $k = 5$ mẫu ($T > 0$).

Chỉ số: độ chính xác sau kiểm chứng, số token, độ chính xác và độ phủ của việc gắn nhãn dự đoán sai, tỷ lệ chấp nhận sai.

**Nhận xét phê phán (diễn giải của nhóm, chưa kiểm chứng độc lập)**

$V_{\text{exec}}$ có kết quả đúng theo cấu tạo trên bộ dữ liệu này vì đáp án cũng lấy bằng thực thi. Tuyên bố hợp lệ chỉ là: với hàm thuần có thể thực thi, ở mức bằng chứng E2, bằng chứng thực thi có hiệu quả hơn giám khảo LLM và biểu quyết ở chi phí nhất định. Không khái quát sang

mã không thể thực thi hoặc có tác dụng phụ. Có thể mở rộng sang kiểm chứng một phần (chỉ thực thi lát cắt) ở P2.

### II.8.8. Ước lượng ngân sách tính toán

Ước lượng cho mức P0, $n = 200$ mỗi ô, độ dài $\{4\text{k}, 16\text{k}\}$ (trung bình 10 k token), chỉ tính token đầu vào:

**Bảng 13.** Ước lượng token đầu vào mỗi mô hình (mức P0)

| Hạng mục | Số truy vấn | Token trung bình/truy vấn | Tổng (triệu) |
|---|---|---|---|
| D2, C1 (2 độ dài × 3 vị trí) | 1 200 | 10 000 | 12,0 |
| D2, C2 (2 độ dài) | 400 | 10 000 | 4,0 |
| D2, C4a (2 độ dài) | 400 | 2 000 | 0,8 |
| D2, C3 và C0 | 400 | 1 000 | 0,4 |
| D1, SemTrace 3 và 4 chữ số (2 × 2 × 3) | 2 400 | 10 000 | 24,0 |
| D1, truy xuất hàm (2 × 3) | 1 200 | 10 000 | 12,0 |
| Tổng mỗi mô hình | | | 53,2 |
| Tổng ba mô hình | | | khoảng 160 |

Đây là ước lượng thô: chưa tính token đầu ra, chưa tính chi phí nhúng của C4, chưa tính giá thực tế hay hạn mức API, và mở rộng lên 32k hoặc nhiều vị trí hơn làm tăng tỷ lệ thuận. Nếu ngân sách không đủ, các cách giảm theo thứ tự ưu tiên: giảm $n$ về 100 (và chấp nhận chỉ phát hiện hiệu ứng lớn hơn 20 điểm phần trăm), bỏ tác vụ truy xuất hàm ở mô hình thương mại, dùng một mô hình thương mại chỉ với tập con như [2] đã làm với GPT-4.1 (một phần tám bộ dữ liệu).

## II.9. Cách thức thực hiện

### II.9.1. Quy trình theo bước

1. **Chuẩn bị**: tạo kho Git chung; khóa phiên bản thư viện; lược đồ cấu hình YAML cho mỗi lần chạy (mô hình, điều kiện, độ dài, vị trí, hạt giống); nhật ký JSONL cho mỗi truy vấn (mã băm lời nhắc, mô hình và phiên bản, tham số, đầu ra thô, đầu ra đã phân tích, token, độ trễ).
2. **Bộ sinh D1/D2**: cài đặt bộ sinh theo hạt giống; kiểm thử đơn vị; kiểm chéo đáp án bằng hai bộ đánh giá; kiểm tra thống kê mô tả (phân bố độ dài token, phân bố vị trí).

3. **Bộ dựng ngữ cảnh**: cài đặt C0–C4a; bộ đếm token theo bộ mã hóa của từng mô hình; đo độ phủ và độ tinh khiết của C3 và C4a.
4. **Chạy thử (pilot)**: $n = 20$ mỗi ô, một mô hình mở nhỏ; kiểm tra phân tích đầu ra, chi phí thực tế, thời gian; đối chiếu với Bảng 3 của [2] ở mức không có hàm gây nhiễu (sai lệch chấp nhận được do nhóm đặt trước, đề xuất không quá 10 điểm phần trăm vì mô hình, lời nhắc và phiên bản có thể khác).
5. **Đóng băng**: ghi giả thuyết, ngưỡng, danh sách đối chiếu K1–K5 và cấu hình vào kho (gắn thẻ phiên bản) trước khi chạy tập kiểm tra.
6. **Chạy chính (P0)** và **phân tích**: sinh bảng, hình, khoảng tin cậy; phân tích sai.
7. **Mở rộng (P1/P2)** nếu còn thời gian: C4b, suy luận từng bước, độ dài 32k, gọi gián tiếp, RQ3.
8. **Viết**: song song từ tuần đầu (Chương Tổng quan và Cơ sở lý thuyết), hoàn thiện sau khi có kết quả.

## II.9.2. Công cụ đề xuất

Python và thư viện `ast` cho phân tích tĩnh, NetworkX cho đồ thị gọi hàm, Tree-sitter (cho D4), một mô hình nhúng mã mã nguồn mở, vLLM hoặc Ollama cho mô hình mở (nếu có GPU) hoặc API của nhà cung cấp, pandas, SciPy và statsmodels cho thống kê, Matplotlib cho hình, Git cho quản lý phiên bản. Môi trường cô lập: tiến trình con có giới hạn thời gian và bộ nhớ, không mạng, hoặc container.

**Cần xác nhận về công cụ**

Người soạn không biết nhóm có GPU, ngân sách API, hay công cụ AI nào đã thông thạo (hướng dẫn cho phép "thử nghiệm với công cụ mà nhóm đã thông thạo"). Danh sách trên là đề xuất mặc định.

## II.9.3. Cấu trúc kho mã đề xuất

```
repo/
  README.md             # cách chạy, phiên bản, giấy phép
  configs/              # YAML cho từng lần chạy
  prereg/               # giả thuyết, ngưỡng, đối chiếu (đóng băng)
  src/gen/              # bộ sinh D1, D2 (hạt giống)
  src/context/          # C0..C4: AST, đồ thị gọi hàm, truy xuất
  src/run/              # gọi mô hình, ghi nhật ký JSONL
  src/analysis/         # thống kê, hình, phân tích sai
  data/dev/ data/test/  # sinh từ hạt giống riêng
```

```
logs/                # nhật ký thô (không sửa tay)
paper/               # LaTeX hoặc Word của bài báo
```

# II.10. Tái lập và báo cáo theo quy trình tối thiểu

Bảng 14 ánh xạ bảy nhóm thông tin trong quy trình báo cáo tối thiểu của [3] sang nội dung nhóm sẽ báo cáo.

**Bảng 14.** Ánh xạ quy trình báo cáo tối thiểu [3] sang đề tài

| Nhóm thông tin | Nội dung nhóm sẽ báo cáo |
|---|---|
| Tác vụ và đối tượng | Dự đoán đầu ra của hàm Python thuần; mức hàm; chỉ Python (P0); tuyên bố giới hạn ở mức E2 |
| Mô hình và thích nghi | Tên và phiên bản/ngày của mô hình, tham số giải mã, lời nhắc đầy đủ; không tinh chỉnh; cấu hình truy xuất của C4 |
| Khung chạy và công cụ | Không dùng tác tử; công cụ chỉ gồm bộ dựng ngữ cảnh và bộ thực thi cô lập; ghi phiên bản thư viện |
| Ngân sách và đầu vào của người | Số truy vấn, token, thời gian, chi phí; không có can thiệp của người trong lúc chạy |
| Dữ liệu và nhiễm dữ liệu | Hạt giống, cách sinh, kiểm tra nguy cơ nhiễm (hằng số ngẫu nhiên, tên ngẫu nhiên), nguồn và giấy phép hàm gây nhiễu |
| Kiểm chứng | Đáp án bằng thực thi, kiểm chéo bằng bộ đánh giá thứ hai; không có kiểm thử bảo mật |
| Độ bất định và thất bại | Khoảng tin cậy bootstrap, chạy lặp tập con, kết quả âm tính, phân loại lỗi |

# II.11. Mối đe dọa đối với tính hợp lệ

**Bảng 15.** Mối đe dọa đối với tính hợp lệ và biện pháp giảm nhẹ

| Loại | Mối đe dọa | Biện pháp (và giới hạn còn lại) |
|---|---|---|
| Nội tại | Lỗi bộ sinh hoặc bộ phân tích đầu ra; nhạy với lời nhắc | Kiểm chéo bằng hai bộ đánh giá; tập phát triển/kiểm tra tách hạt giống; kiểm tra thủ công mẫu đầu ra thô. Nhạy với lời nhắc chỉ được đánh giá ở mức P1 (một biến thể) |
| Cấu trúc | Độ chính xác trên số học tổng hợp là chỉ báo gián tiếp của "hiểu mã"; độ nhạy phụ thuộc mô hình [2]; đồ thị gọi hàm trong mã sinh dễ hơn mã thực | Dùng 3–4 chữ số; báo cáo mức chắc chắn; thêm biến thể gọi gián tiếp ở P1. Không loại trừ hết |
| Ngoại suy | Chỉ Python, hàm thuần, ngữ cảnh tối đa 16k–32k, vài mô hình, một thời điểm | Nêu rõ giới hạn; không khẳng định trên kho mã thực; D4 và RQ4 là phần mở rộng |
| Kết luận | Cỡ mẫu giới hạn; đa so sánh; phi tất định của API | Hiệu chỉnh Holm; báo cáo khoảng tin cậy; chạy lặp tập con. Hiệu ứng nhỏ hơn 15 điểm phần trăm không đủ hiệu lực |
| Nhiễm dữ liệu | Mô hình có thể đã ghi nhớ số học hoặc mẫu hàm | Hằng số và tên ngẫu nhiên; ba đến bốn chữ số [2]; không loại trừ hết với mô hình đóng |
| Tái lập | Mô hình thương mại thay đổi; phụ thuộc phần cứng | Ghi phiên bản và ngày; ghi nhật ký; ưu tiên mô hình mở cho kết quả chính |

## II.11.1. Kiểm tra tái lập số liệu cơ sở của [2]

Trước khi chạy thực nghiệm mới, nhóm đối chiếu độ chính xác không có hàm gây nhiễu của mô hình mốc với Bảng 3. Nếu chênh lệch vượt ngưỡng đã đặt (đề xuất 10 điểm phần trăm), nhóm điều tra nguyên nhân (lời nhắc, bộ phân tích, phiên bản) và báo cáo, không tiếp tục như thể đã tái lập.

## II.11.2. Đạo đức, an toàn và sử dụng AI

Thực thi mã sinh tự động chỉ trong môi trường cô lập; không dùng dữ liệu cá nhân; kiểm tra giấy phép của mã gây nhiễu; ghi nhật ký sử dụng công cụ AI cho nghiên cứu và soạn thảo (Phụ lục A của file Word mẫu); thành viên chịu trách nhiệm kiểm tra mọi nội dung do AI tạo ra.

# II.12. Kế hoạch, phân công và tiến độ

## II.12.1. Tiến độ

**Bảng 16.** Tiến độ đề xuất (hôm nay là 07/11/2026)

| Thời gian | Công việc | Đầu ra |
|---|---|---|
| 07–10/11 | Họp nhóm chốt hướng đề tài, RQ, vai trò; xác nhận với giảng viên (qua Teams) nếu cần; chốt mô hình, ngân sách; tra cứu bổ sung tính mới; tạo kho mã | Văn bản chốt RQ; danh sách mô hình; kho mã |
| 10–16/11 | Cài đặt D1, D2, C0–C3, C4a; pilot ($n = 20$); đối chiếu số cơ sở; viết nháp chương Giới thiệu và Tổng quan | Bộ sinh chạy được; kết quả pilot; nháp chương 1–2 |
| 17/11 | Soạn slide báo cáo lần 1 theo mẫu của giảng viên | Slide |
| **18–19/11** | **Báo cáo lần 1** (yêu cầu: ít nhất 2/4 nội dung) | Nội dung 1 (tổng quan, từ khóa) và 2 (RQ, tham khảo, thử công cụ) |
| 19–24/11 | Đóng băng cấu hình; chạy chính P0 (RQ1, RQ2); phân tích sơ bộ; chốt đóng góp và triết lý khoa học; viết chương 3–4 | Kết quả sơ bộ; nội dung 3 |
| **25–26/11** | **Báo cáo lần 2** (yêu cầu: ít nhất 3/4 nội dung) | Nội dung 1–3 và kết quả sơ bộ |
| 27/11–06/12 | P1 (C4b, suy luận từng bước, 32k, gọi gián tiếp, RQ3 nếu còn thời gian); phân tích thống kê hoàn chỉnh; viết bài; **dừng thực nghiệm ngày 06/12** | Kết quả đầy đủ; bản nháp bài |
| 07–15/12 | Hoàn thiện báo cáo đầy đủ (file Word), báo cáo tóm tắt dạng bài báo, slide bảo vệ, mã nguồn, gói tái lập; kiểm tra chéo | Sản phẩm nộp (hạn cụ thể trong tháng 12 cần xác nhận) |

## II.12.2. Phân công theo vai trò

Phân công cụ thể theo tên cần nhóm quyết định, vì người soạn không biết kỹ năng từng thành viên. Bảy vai trò đề xuất (mỗi vai trò nên có một người dự phòng):

**Bảng 17.** Vai trò đề xuất

| Mã | Vai trò | Trách nhiệm chính |
|---|---|---|
| V1 | Điều phối và tích hợp | Theo dõi tiến độ, liên lạc với giảng viên, họp ngắn hằng ngày, quản lý kho mã và phiên bản đóng băng |
| V2 | Tổng quan và trích dẫn | Mở rộng tra cứu tài liệu, đọc toàn văn các bài G2, quản lý danh mục tham khảo, kiểm tra trích dẫn |
| V3 | Bộ sinh dữ liệu | D1, D2, kiểm chéo đáp án, kiểm thử đơn vị |
| V4 | Phân tích chương trình và dựng ngữ cảnh | Đồ thị gọi hàm, C0–C4, đo độ phủ và độ tinh khiết |
| V5 | Hạ tầng chạy mô hình | Gọi mô hình, nhật ký, theo dõi chi phí, xử lý lỗi và giới hạn tốc độ |
| V6 | Thống kê và hình bảng | Phân tích thống kê, hình, phân tích sai |
| V7 | Viết bài, định dạng và kiểm tra trung thực | Bài báo và báo cáo Word, slide, nhật ký sử dụng AI, đối chiếu số liệu với nhật ký |

# II.13. Rủi ro và phương án dự phòng

**Bảng 18.** Rủi ro và phương án dự phòng

| Mã | Rủi ro | Phương án |
|---|---|---|
| R1 | Không đủ ngân sách API hoặc GPU | Giảm $n$ về 100; ưu tiên mô hình mở nhỏ; dùng tập con cho mô hình thương mại; bỏ độ dài 32k |
| R2 | Không tái lập được hiệu ứng ở RQ1 (kết quả âm) | Báo cáo như kết quả; chuyển trọng tâm sang RQ2 ở độ dài lớn hơn hoặc mô hình yếu hơn; điều chỉnh tên đề tài |
| R3 | Sắp xếp lại (C2) giải thích gần hết cải thiện | Báo cáo như phát hiện chính; mô tả vai trò của phân tích chương trình là xác định mã cần sắp xếp |
| R4 | Đồ thị gọi hàm tĩnh trên mã sinh quá dễ (kết quả C3 thuận lợi giả tạo) | Thêm biến thể gọi gián tiếp ở P1; nêu giới hạn |
| R5 | Chậm tiến độ | Giữ phân tầng P0/P1/P2; dừng thực nghiệm 06/12; cắt RQ3 trước, sau đó C4b |
| R6 | Tính mới bị phản biện | Định vị rõ so với [2, 8, 10, 11]; không khẳng định phương pháp mới; bổ sung tra cứu trước khi viết |
| R7 | Mục tiêu điểm A (bài đủ điều kiện công bố) chưa đạt | Dành thời gian viết từ tuần đầu; kiểm tra chéo; nếu cần, hạ phạm vi để bảo đảm hoàn chỉnh (mức B yêu cầu mọi khâu hoàn thành) |

# II.14. Sản phẩm và đối chiếu với tiêu chí chấm

Hướng dẫn xếp điểm theo mức hoàn thành bốn nội dung (nghiên cứu tài liệu và từ khóa; ít nhất 03 RQ; đóng góp và triết lý khoa học; bài báo đủ để đăng arXiv).

**Bảng 19.** Đối chiếu bốn nội dung yêu cầu của hướng dẫn với đề cương

| Nội dung yêu cầu | Đáp ứng trong đề cương | Mốc dự kiến |
|---|---|---|
| 1. Nghiên cứu tài liệu, từ khóa, tìm thêm tài liệu | Phần I; danh mục từ khóa (Phụ lục C); mở rộng bởi V2 | 18–19/11 |
| 2. Ít nhất 03 RQ, tài liệu tham khảo, cách thực hiện, thử công cụ | Mục II.6, phương pháp và cách thức thực hiện; pilot | 18–19/11 |
| 3. Đóng góp khoa học, triết lý khoa học | Mục II.7 (đề xuất); chốt sau kết quả sơ bộ | 25–26/11 |
| 4. Bài báo đủ điều kiện đăng arXiv | Cấu trúc ở mục II.14.1; cần kết quả thực nghiệm | Tháng 12 |

**Sản phẩm nộp:** báo cáo đầy đủ (file Word theo quy cách), báo cáo tóm tắt dạng bài báo khoa học, slide trình bày, các tài liệu hướng dẫn, mã nguồn và dữ liệu (nộp bản mềm vào thư mục giảng viên chia sẻ).

## II.14.1. Cấu trúc bài báo dự kiến

Theo mục III.2 của hướng dẫn: Giới thiệu; Tổng quan và định hướng giải pháp; Cơ sở lý thuyết; Giải pháp đề xuất; Cài đặt, thực nghiệm và đánh giá; Kết luận và hướng phát triển.

**Bảng 20.** Cấu trúc bài báo dự kiến

| Mục | Nội dung | Số trang |
|---|---|---|
| 1. Giới thiệu | Bối cảnh, vấn đề, RQ, đóng góp, cấu trúc | 1,0 |
| 2. Tổng quan | [1, 2, 3, 4] và các công trình bổ sung; khoảng trống G1–G5 | 1,5 |
| 3. Cơ sở lý thuyết | Lexical/semantic recall, độ nhạy, đồ thị gọi hàm, truy xuất | 1,0 |
| 4. Giải pháp (bộ dữ liệu và điều kiện) | SemTrace-Dep, C0–C4, đối chiếu K1–K5 | 1,5 |
| 5. Thực nghiệm | Thiết lập, kết quả RQ1–RQ3, phân tích sai, thảo luận, mối đe dọa | 3,0 |
| 6. Kết luận | Trả lời RQ, giới hạn, hướng phát triển | 0,5 |
| Tài liệu tham khảo, phụ lục | | 1,0 |

Số trang là ước lượng tham khảo, không có yêu cầu trong hướng dẫn. Ngôn ngữ: hướng dẫn cho phép tiếng Việt hoặc tiếng Anh; với mục tiêu arXiv, tiếng Anh thường phù hợp hơn, nhưng cần nhóm và giảng viên xác nhận.

## II.15. Các điểm cần xác nhận

1. Nhóm đã nhất trí hướng đề tài (thực nghiệm đối chứng về semantic recall) hay muốn xem xét hướng khác (khảo sát, tái hiện hệ thống [4])?
2. Giảng viên có kỳ vọng về loại đóng góp (đề xuất giải pháp mới hay nghiên cứu thực nghiệm) cho hướng 5-KH không? “Giải pháp đề xuất” trong hướng dẫn có thể được hiểu là phương pháp mới.
3. Ngân sách API, GPU hoặc tài khoản dịch vụ mô hình mà nhóm có.
4. Ngày hạn cụ thể của sản phẩm cuối trong tháng 12 và mẫu slide báo cáo tiến độ.
5. Ngôn ngữ của bài báo (Việt hoặc Anh) và mẫu bìa của hướng dẫn (“theo mẫu”, chưa có trong thư mục).
6. Có cần phân tích các công bố do chính giảng viên là tác giả không (xem giả định ở mục I.1.1).

# Tài liệu tham khảo

[1] Q. Zhang và cộng sự, "A survey on large language models for software engineering," *arXiv preprint* arXiv:2312.15223v2, Sep. 2024.

[2] A. Štorek và cộng sự, "Sense and sensitivity: Examining the influence of semantic recall on long context code understanding," *arXiv preprint* arXiv:2505.13353v5, Jul. 2026.

[3] W. Lin và cộng sự, "Large language models at the intersection of software engineering and software security: An evidence-centered structured survey and research agenda," *arXiv preprint* arXiv:2608.21107v1, Aug. 2026.

[4] S. Roychowdhury và cộng sự, "Code Comprehensor: Hierarchical documentation and cross-modal retrieval for large repositories," *arXiv preprint* arXiv:2610.30016v2, Oct. 2026.

[5] F. Nielson, H. R. Nielson, and C. Hankin, *Principles of Program Analysis*. Berlin, Germany: Springer, 2010.

[6] A. Gu và cộng sự, "CRUXEval: A benchmark for code reasoning, understanding and execution," *arXiv preprint* arXiv:2401.03065, Jan. 2024.

[7] N. F. Liu và cộng sự, "Lost in the middle: How language models use long contexts," *arXiv preprint* arXiv:2307.03172v3, Nov. 2023.

[8] Y. Shi và cộng sự, "LongCodeZip: Compress long context for code language models," *arXiv preprint* arXiv:2510.00446, Oct. 2025.

[9] S. Ouyang và cộng sự, "RepoGraph: Enhancing AI software engineering with repository-level code graph," *arXiv preprint* arXiv:2410.14684v2, Mar. 2025.

[10] H. Jia, E. T. Barr, and S. Mechtaev, "Compressing code context for LLM-based issue resolution," *arXiv preprint* arXiv:2603.28119, Mar. 2026.

[11] F. Mächtle và cộng sự, "Trace Gadgets: Minimizing code context for machine learning-based vulnerability prediction," *arXiv preprint* arXiv:2504.13676, Apr. 2025.

[12] J. Porbeck, C. M. Adriano, and H. Giese, "From program slices to causal clarity: Evaluating faithful, actionable LLM-generated failure explanations via context partitioning and LLM-as-a-judge," in *Proc. Int. Conf. Evaluation and Assessment in Software Engineering (EASE '26)*, Glasgow, U.K., Jun. 2026; arXiv:2604.18309.

[13] Z. Liu và cộng sự, "When is LLM-based program reasoning correct? A completion semantics for LLM-based code inference," *arXiv preprint* arXiv:2607.12490, Jul. 2026.

[14] Y. Li và cộng sự, "An execution-verified multi-language benchmark for code semantic reasoning," *arXiv preprint* arXiv:2605.11006, May 2026.

[15] K. R. Popper, *The Logic of Scientific Discovery*. London, U.K.: Routledge, 2002.

**Ghi chú về nguồn tham khảo**

Năm và tháng của các tài liệu có định danh arXiv được suy ra từ định danh arXiv (YYMM) hoặc từ trang tóm tắt arXiv; địa điểm công bố (tạp chí, hội nghị) chỉ ghi khi trang nguồn nêu rõ. Với các bài ở mục [6]–[14], người soạn chỉ đọc trang tóm tắt, không đọc toàn văn. Một bài tìm thấy khi tra cứu (arXiv:2603.01896, "Agentic Code Reasoning") chỉ xác minh được tiêu đề và mô tả một câu, không có thông tin tác giả, nên không được đưa vào danh mục tham khảo.

# Phụ lục A. Ví dụ minh họa một mục của SemTrace-Dep

Mã dưới đây do người soạn viết để minh họa đặc tả (không lấy từ bài nào); bộ sinh thực tế chưa được cài đặt. Hàm đích là `fn_92be`; tập mã cần thiết là `fn_c01d` và `fn_7f3a`; hàm `tokenize_line` là hàm gây nhiễu không liên quan.

```
def tokenize_line(s):                 # hàm gây nhiễu (không được gọi)
    return [t for t in s.split() if t]

def fn_7f3a(x):                       # cần thiết (độ sâu 2)
    a = x + 214
    b = a - 87
    return b + 531

def fn_c01d(x):                       # cần thiết (độ sâu 1), gọi fn_7f3a
    a = fn_7f3a(x) - 342
    b = a + 120
    return b - 405

def fn_92be(x):                       # hàm đích
    r = fn_c01d(x + 15)
    s = fn_7f3a(r) + 263
    return [r, s]
```

Với $x = 81$, thực thi cho kết quả `[127, 1048]` (đã chạy kiểm tra bằng Python). Chương trình phản thực dùng cho phân tích sai: nếu mô hình bỏ qua lời gọi `fn_7f3a` trong `fn_c01d` (coi như bằng đầu vào), `r` sẽ là $-531$ thay vì $127$; đầu ra của mô hình khớp với kịch bản nào giúp gán nguyên nhân sai.

**Nhận xét phê phán (diễn giải của nhóm, chưa kiểm chứng độc lập)**

Trong ví dụ này, mỗi hàm rút gọn thành phép cộng một hằng số vào đầu vào, nên một mô hình có thể đạt kết quả đúng nhờ tự rút gọn thay vì nhớ từng dòng. Đây là điểm cần cân nhắc khi chốt tham số $m$ và loại phép toán; SemTrace gốc [2] tránh điều này bằng cách mỗi dòng gán vào một phần tử riêng của danh sách.

# Phụ lục B. Khuôn mẫu lời nhắc (đề xuất)

```
You are given Python source code. Read it carefully and answer the question.
Question: What does fn_92be(81) return? Answer with the Python literal only.

<code>
...ngữ cảnh theo điều kiện C0-C4...
</code>

Question (repeated): What does fn_92be(81) return? Answer with the Python literal only.
```

Việc lặp câu hỏi trước và sau mã theo [2]. Khuôn mẫu này chưa được thử; nhóm cần kiểm tra trên tập phát triển.

# Phụ lục C. Danh mục từ khóa tìm kiếm

- Tiếng Anh: large language model; code understanding; code reasoning; semantic recall; long context; lost in the middle; program slicing; call graph; retrieval-augmented generation; repository-level; code search; hallucination; execution-based verification; benchmark; reproducibility; context compression.
- Tiếng Việt: mô hình ngôn ngữ lớn; hiểu mã nguồn; ngữ cảnh dài; cắt lát chương trình; đồ thị gọi hàm; sinh tăng cường bằng truy xuất; kiểm chứng bằng thực thi.

# Phụ lục D. Các truy vấn tra cứu bổ sung đã thực hiện

Các truy vấn dùng công cụ tìm kiếm web trong phiên làm việc (không phải tổng quan hệ thống): (1) program slicing to reduce context for LLM code reasoning; (2) CRUXEval code reasoning benchmark; (3) Lost in the Middle; (4) RepoGraph repository-level code graph; (5) LLM program execution tracing and static analysis hybrid verification; (6) LongCodeZip; (7) RepoGraph arXiv; (8) lost in the middle in code, dependency-aware context ordering; (9)

semantic recall SemTrace follow-up citations. Kết quả của (8) và (9) không cho công trình nào bổ sung trực tiếp ngoài các bài đã liệt kê.

# Phụ lục E. Thuật ngữ Việt – Anh

**Bảng 21.** Thuật ngữ dùng trong tài liệu

| Tiếng Việt | Tiếng Anh |
|---|---|
| Khả năng nhớ nguyên văn mã | Lexical (code) recall |
| Khả năng nhớ ngữ nghĩa thực thi | Semantic (code) recall |
| Độ nhạy khôi phục ngữ nghĩa | Semantic recall sensitivity |
| Hàm gây nhiễu | Distractor function |
| Bao đóng đồ thị gọi hàm | Call-graph closure |
| Cắt lát chương trình | Program slicing |
| Sinh tăng cường bằng truy xuất | Retrieval-augmented generation (RAG) |
| Giám khảo LLM | LLM-as-a-judge |
| Biểu quyết tự nhất quán | Self-consistency |
| Chương trình phản thực | Counterfactual program |

# Phụ lục F. Danh sách các điểm chưa xác minh

1. Đơn vị và tập lấy trung vị của con số 92,73% và 53,36% trong [2] (mục I.2.2).
2. Tình trạng bình duyệt và địa điểm công bố của cả bốn bài và các công trình bổ sung.
3. Toàn văn của [6, 7, 8, 9, 10, 11, 12, 13, 14]: chỉ đọc trang tóm tắt.
4. Tính mới của hướng đề xuất: chỉ dựa trên các truy vấn ở Phụ lục D.
5. Giấy phép của CodeSearchNet và CRUXEval cho việc dùng và phân phối lại.
6. Tên và tình trạng sẵn có của các mô hình sẽ dùng, giá và hạn mức.